Bài tập lớn A1: CNN và Transformer

CO5085 Học sâu và ứng dụng trong thị giác máy tính, học kỳ 261 (2026–2027)

Huỳnh Văn Tâm Thiện (2470094)
Lê Hữu Trọng (2470578)

Giảng viên: TS. Lê Thành Sách, TS. Nguyễn Quốc Minh
Trường Đại học Bách Khoa, ĐHQG-HCM

22/10/2026

Mục lục

1 Tóm tắt **2**

2 Mục tiêu **3**

3 Tập dữ liệu **4**

4 Chia train, validation, test **5**

5 Khảo sát dữ liệu **6**

6 Tiền xử lý và tăng cường dữ liệu **8**

7 Mô hình **9**

8 Chế độ huấn luyện **12**

9 Đánh giá **13**

1 Tóm tắt

Báo cáo A1.1: chốt tập dữ liệu, hai mô hình và giao thức thí nghiệm của bài tập lớn A1. Bài tập lớn A1 so sánh một mạng tích chập với một Transformer thị giác trên cùng một tập ảnh lớn, mỗi mô hình ở bốn chế độ huấn luyện.

- **Tập dữ liệu.** Food-101, 101 lớp món ăn. Sau khi tách train, validation và test có 68 175, 7 575 và 25 250 ảnh (Mục 3, 4).
- **Mô hình.** ResNet-50 (`microsoft/resnet-50`) cho CNN và DeiT-S (`facebook/deit-small-patch16-224`) cho Transformer, cả hai là bản công bố trên Hugging Face, có trọng số ImageNet-1k. Chế độ scratch không nạp trọng số đó (Mục 7).
- **Chế độ huấn luyện.** Train từ đầu (*scratch*), chỉ train classification head (*head*), đóng băng nửa đầu mạng (*partial*) và finetune toàn bộ (*full*). Hai mô hình nhân bốn chế độ thành 8 run, seed 42 (Mục 8).
- **Tiền xử lý.** Một pipeline tăng cường và chuẩn hoá, dùng chung cho mọi mô hình và mọi chế độ (Mục 6).

Hạng mục	Liên kết	Nội dung được dùng
Food-101	huggingface.co/datasets/ethz/food101	Thẻ mô tả do nhóm ETH Zürich đăng: 101 lớp, 750 ảnh train và 250 ảnh test mỗi lớp
Điều khoản sử dụng	huggingface.co/datasets/ethz/food101#license-agreement	Không có giấy phép mở. Dữ liệu chỉ được dùng để học và nghiên cứu
ResNet-50	huggingface.co/microsoft/resnet-50	ResNet v1.5 (bước nhảy 2 ở tích chập 3×3), pretrain trên ImageNet-1k ở 224×224; thẻ mô tả không nêu công thức huấn luyện hay accuracy (Mục 7)
DeiT-S	huggingface.co/facebook/deit-small-patch16-224	DeiT-small không có token chưng cất, train trên ImageNet-1k ở 224×224, top-1 79.8% theo bài báo DeiT

Bảng 1: Nguồn của tập dữ liệu, điều khoản sử dụng và hai bộ trọng số.

2 Mục tiêu

Bài tập lớn A1 so sánh một mạng tích chập (CNN) và một Vision Transformer (ViT) trên một tập ảnh đủ lớn và đủ khó để khác biệt giữa hai họ kiến trúc, và giữa các cách dùng trọng số pretrained, có ý nghĩa. Bài chọn **Food-101** (101 món ăn, 101 000 ảnh), **ResNet-50** cho họ CNN và **DeiT-S** cho họ Transformer. Mỗi mô hình được huấn luyện theo bốn chế độ: từ đầu (*scratch*), và ba cách dùng trọng số pretrained ImageNet-1k là chỉ train classification head (*head*), đóng băng nửa đầu mạng (*partial*) và finetune toàn bộ (*full*).

3 Tập dữ liệu

Food-101 gồm 101 lớp món ăn, mỗi lớp 1 000 ảnh (750 ảnh train và 250 ảnh test theo split chính thức), cạnh dài nhất của ảnh không quá 512 px. Ảnh test đã được kiểm tra thủ công; ảnh train cố ý để nguyên nên còn nhiễu, chủ yếu là màu quá gắt và đôi khi sai nhãn.

Food-101 được chọn vì bốn lý do:

- **Đủ lớn và đủ khó.** 101 lớp, 75 750 ảnh train chính thức; bài toán phân loại chi tiết, nhiều món khác nhau trông gần giống nhau.
- **Không trùng với ImageNet.** Tiny-ImageNet, Imagenette và các tập con của ImageNet bị loại vì ảnh của chúng nằm trong dữ liệu mà mô hình pretrained đã học, làm lệch so sánh scratch với pretrained.
- **Hợp với mô hình pretrained.** Ảnh tự nhiên, dùng được ở độ phân giải 224 px; CIFAR-100 (32×32) phải phóng to gấp 7 lần nên bị loại.
- **Vừa ngân sách.** Khoảng 68 000 ảnh train đủ nhỏ để train từ đầu trên một GPU L4.

Lưu ý: ImageNet-1k có sẵn một số lớp món ăn trùng hoặc gần với Food-101, nên trọng số pretrained có lợi thế ngữ nghĩa ở các lớp này; A1.2 sẽ xem accuracy từng lớp có phản ánh điều đó không.

4 Chia train, validation, test

Split test chính thức được giữ nguyên. Validation được tách từ split train chính thức: 10% mỗi lớp, phân tầng theo nhãn, seed 42 (Bảng 2). Split này cố định cho mọi run, ở cả hai mô hình và cả bốn chế độ, nên scratch và pretrained được so sánh trên cùng một split.

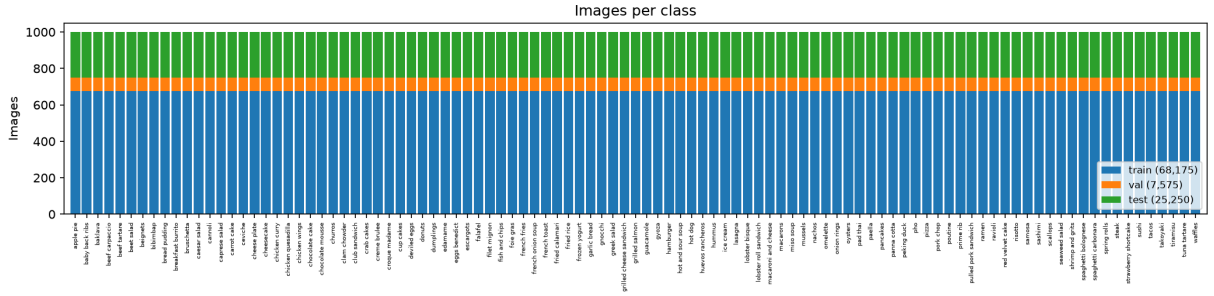
Tập	Số ảnh	Ảnh/lớp	Nguồn
train	68 175	675	90% split train chính thức
validation	7 575	75	10% split train chính thức
test	25 250	250	split test chính thức

Bảng 2: Ba tập dùng trong A1.

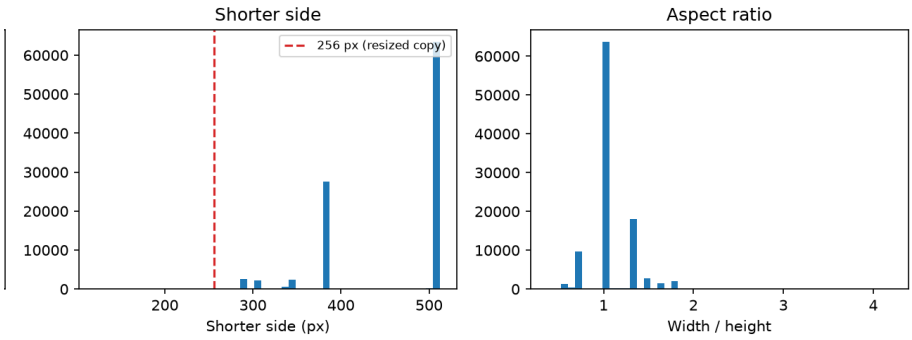
- **Test chỉ dùng một lần,** sau khi train xong; mọi quyết định (epoch giữ lại, learning rate) dựa trên validation.
- **Validation lấy từ train, không từ test,** để test không tham gia chọn mô hình.
- **Nhiễu nhãn:** validation lấy từ train nên cũng nhiễu, còn test đã được kiểm tra thủ công; validation accuracy vì vậy có thể thấp hơn test accuracy.

5 Khảo sát dữ liệu

Kích thước ảnh được đo trên toàn bộ 101 000 ảnh gốc, trước khi thu nhỏ; mean và std theo kênh được tính trên toàn bộ 68 175 ảnh train, sau bước cắt cố định (Hình 1–3, Bảng 3).



Hình 1: Số ảnh mỗi lớp trong train, validation và test.



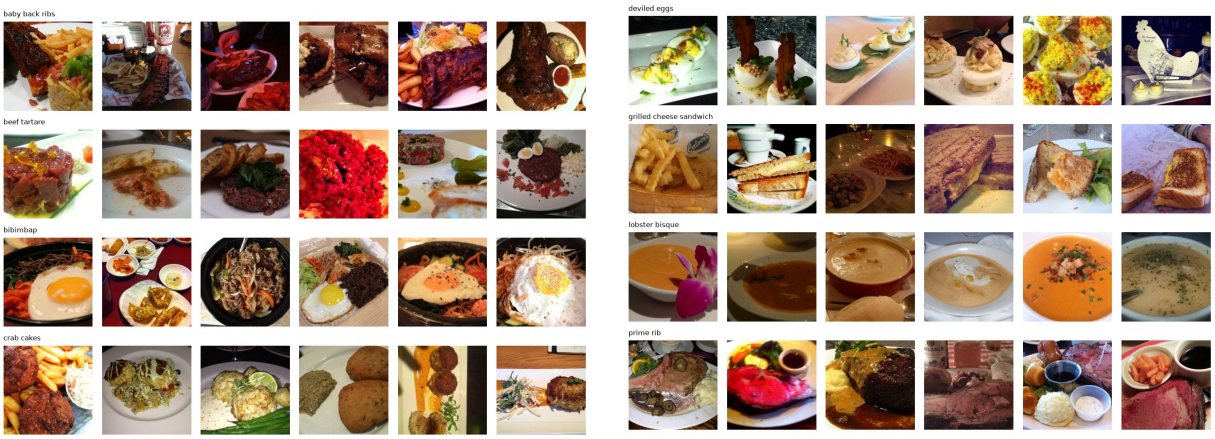
Hình 2: Kích thước ảnh gốc. Trái: số ảnh theo độ dài cạnh ngắn (vạch đỏ là 256 px, mức đổi cạnh ngắn trước khi cắt). Phải: số ảnh theo tỉ lệ khung (rộng/cao).

Đại lượng	Giá trị
Ảnh gốc	101 000 (L 3, RGB 100 997)
Cạnh dài (px)	512–512, trung vị 512
Cạnh ngắn (px)	122–512, trung vị 512
Cạnh ngắn < 256 px	44 ảnh
Tỉ lệ rộng/cao	0.38–4.20, trung vị 1.00
Mean RGB (68 175 ảnh train)	(0.557, 0.442, 0.327)
Std RGB	(0.260, 0.264, 0.266)

Bảng 3: Thống kê ảnh gốc và mean/std theo kênh RGB.

Nhận xét.

- **Cân bằng lớp.** Mỗi lớp có đúng 675 ảnh train, 75 ảnh validation và 250 ảnh test (Hình 1), nên không cần trọng số lớp.
- **Kích thước.** Cạnh dài luôn là 512 px. Theo Hình 2, khoảng 63% ảnh là ảnh vuông 512×512 và khoảng 27% có cạnh ngắn 384 px (khung 4:3); các tỉ lệ này đọc từ biểu đồ nên chỉ xấp xỉ. Chỉ 44 ảnh (0.04%) có cạnh ngắn dưới 256 px, được phóng lên khi đổi cạnh ngắn về 256 px, và quá ít để ảnh hưởng kết quả. Phép cắt giữa bỏ phần rìa của ảnh, đáng kể nhất với ảnh có khung dài (tỉ lệ đến 4.2), nhưng các ảnh này rất hiếm.
- **Chế độ màu.** 100 997 ảnh RGB và 3 ảnh xám (chuyển sang RGB khi tiền xử lý).
- **Màu sắc.** Mean RGB là $(0.557, 0.442, 0.327)$, std khoảng 0.26: ảnh món ăn nghiêng về đỏ hơn ImageNet $(0.485, 0.456, 0.406)$.



Hình 3: Ảnh train của một số lớp, sau bước cắt cố định. Bên trái: bốn lớp đầu; bên phải: bốn lớp sau.

- **Nhiễu nhãn** (Hình 3). Ảnh chụp trong nhà hàng nên ánh sáng, góc chụp và nền rất khác nhau. Trong 48 ảnh mẫu có ít nhất hai ảnh mà nhãn không ứng với chủ thể rõ ràng (ảnh thứ hai của *bibimbap* chủ yếu là há cảo; ảnh thứ ba của *grilled cheese sandwich* không thấy bánh) và vài ảnh có màu rất gắt, đúng như tác giả mô tả. Mẫu quá nhỏ để ước lượng tỉ lệ nhiễu.
- **Cặp lớp dễ nhầm**: các món gần nhau như *prime rib*, *steak*; sẽ được đo ở A1.2 bằng ma trận nhầm lẫn (Mục 9).

6 Tiền xử lý và tăng cường dữ liệu

Mọi mô hình và mọi chế độ dùng chung một pipeline dữ liệu, giống MNIST ở E1 và E2: các run chỉ khác nhau ở mô hình và cách huấn luyện, không khác ở dữ liệu đưa vào.

Cắt cố định, áp dụng một lần cho mọi ảnh. Mọi ảnh của cả ba tập (train, validation, test) được xử lý đúng một lần theo cùng một cách: chuyển sang RGB, đổi cạnh ngắn về 256 px (giữ tỉ lệ, nội suy bicubic; ảnh nhỏ hơn được phóng lên), rồi cắt phần giữa 224×224 và lưu lại dạng JPEG.

Sau bước đó, chỉ tập train được tăng cường dữ liệu (Bảng 4, Hình 4); validation và test chỉ được chuẩn hoá.

Bước	Train	Validation, test và tập train dùng để đánh giá
Cắt cố định (một lần, mọi ảnh)	Đổi cạnh ngắn về 256 px, cắt giữa 224×224	như train
Lật	Lật ngang với xác suất 0.5	–
Xoay	Xoay ngẫu nhiên trong khoảng $\pm 15°$	–
Màu	Độ sáng, tương phản, độ bão hoà đổi trong $\pm 20\%$; sắc độ xoay trong ± 0.1 vòng màu ($\pm 36°$)	–
Dịch	Dịch ngẫu nhiên tối đa 10% theo mỗi chiều	–
Chuẩn hoá	Đưa về tensor trong $[0, 1]$, rồi trừ mean 0.5 và chia std 0.5 trên từng kênh	như train

Bảng 4: Pipeline dữ liệu dùng chung, theo đúng thứ tự áp dụng.



Hình 4: Cột đầu: ảnh sau bước cắt cố định. Các cột sau: cùng ảnh qua các phép tăng cường của pipeline train sáu lần.

7 Mô hình

Cả hai mô hình có cùng một khung: một **feature extractor** biến ảnh thành một vector đặc trưng mô tả nội dung ảnh, và một **classification head** biến vector đó thành 101 điểm số, mỗi điểm cho một món. Khác nhau ở feature extractor: ResNet-50 là mạng tích chập, quét ảnh bằng các filter nhỏ và thu nhỏ ảnh dần qua từng stage; DeiT-S là Transformer, cắt ảnh thành các patch rồi cho mọi patch trao đổi thông tin với nhau bằng self-attention. Mục 7.1 và 7.2 trình bày cấu trúc của từng mô hình và chức năng của các lớp trong đó.

Hai mô hình dùng trọng số công bố trên Hugging Face (Bảng 1), có số tham số và chi phí tính toán gần nhau, và cùng được pretrain chỉ trên ImageNet-1k để nguồn pretrain không làm lệch so sánh (Bảng 5). Classification head được thay bằng một linear layer 101 đầu ra, khởi tạo ngẫu nhiên. Số tham số và kích thước đầu ra dưới đây được đo trực tiếp trên mô hình.

Họ	Mã trên Hugging Face	Tham số (đầu 1000 lớp)	Tham số (đầu 101 lớp)	GMAC/ảnh	Pretrain
CNN	`microsoft/resnet-50`	25 557 032	23 714 981	4.09	ImageNet-1k
Transformer	`facebook/deit-small-patch16-224`	22 050 664	21 704 549	4.60	ImageNet-1k

Bảng 5: Hai mô hình. Số tham số của bản Hugging Face (classification head 1000 lớp của ImageNet) và của mô hình dùng trong bài (101 lớp cho Food-101); hai số chênh nhau đúng bằng phần chênh của classification head.

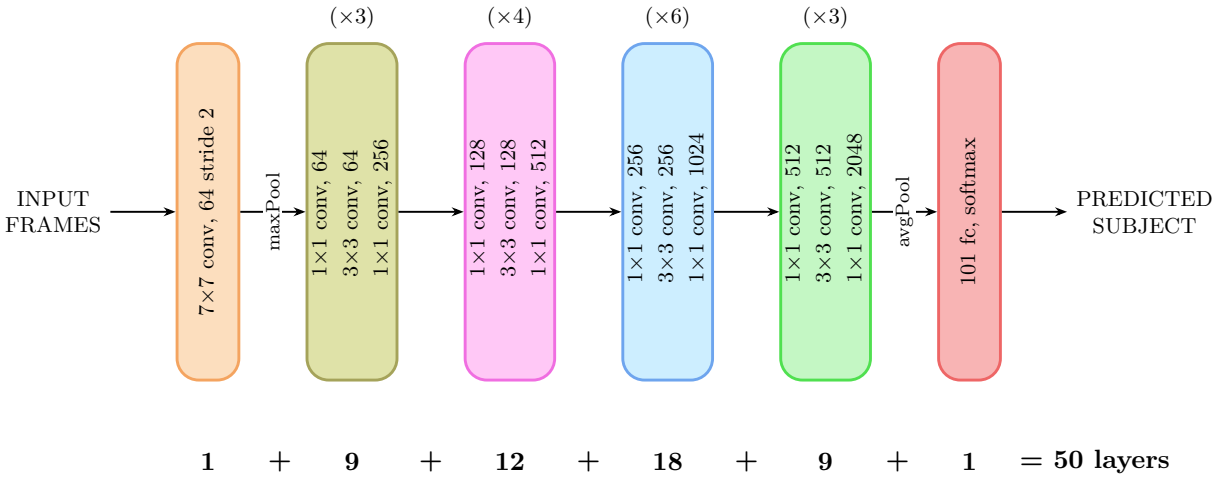
7.1 ResNet-50

ResNet-50 gồm một *stem* (convolution 7×7 và max pooling, thu ảnh từ 224×224 xuống 56×56), bốn *stage* gồm 3, 4, 6 và 3 *bottleneck block*, rồi global average pooling và một fully connected layer 101 đầu ra (Hình 5). Từ stage 2, mỗi stage giảm kích thước ảnh một nửa (còn 28, 14, rồi 7) và tăng gấp đôi số kênh (từ 256 lên 2048).

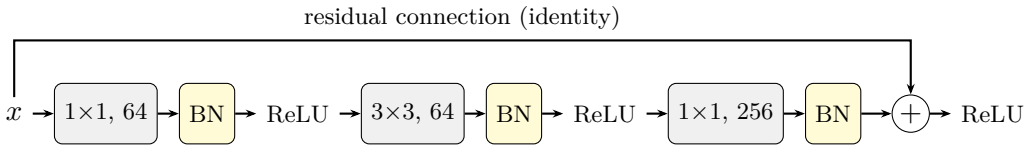
Các layer trong ResNet-50 và chức năng của chúng:

- **Convolution:** trượt các filter nhỏ trên ảnh để phát hiện đặc trưng cục bộ như cạnh, màu, kết cấu; convolution có stride 2 làm ảnh nhỏ đi một nửa.
- **Max pooling:** giữ giá trị lớn nhất trong mỗi vùng 3×3, dùng ở stem để thu nhỏ ảnh một nửa.
- **Batch normalization (BatchNorm):** đặt sau mỗi convolution, chuẩn hoá từng kênh theo trung bình và độ lệch chuẩn của cả batch, giúp train ổn định và nhanh hơn.
- **ReLU (activation function):** hàm kích hoạt phi tuyến, giữ số dương và đặt số âm về 0; thiếu nó, cả mạng chỉ là một phép biến đổi tuyến tính.
- **Residual connection** (*skip connection*): cộng đầu vào của block vào đầu ra, để block chỉ cần học phần thay đổi; nhờ vậy mạng 50 layer vẫn train được.
- **Global average pooling:** lấy trung bình mỗi kênh trên toàn ảnh, biến feature map $2048 \times 7 \times 7$ thành một vector 2048 số.
- **Fully connected layer và softmax:** fully connected layer biến vector 2048 số thành 101 điểm số (logit); softmax đổi chúng thành xác suất của 101 món.

Các layer này được ghép thành *bottleneck block* (Hình 6): convolution 1×1 đầu giảm số kênh (ví dụ 256 xuống 64) để convolution 3×3 chạy trên ít kênh cho rẻ, rồi convolution 1×1 cuối tăng lại gấp 4; ở block đầu mỗi stage, residual connection dùng thêm một convolution 1×1 (*projection shortcut*) để khớp kích thước.



Hình 5: Kiến trúc ResNet-50: mỗi hộp là một stage, ghi các convolution của một bottleneck block và số lần lặp ($\times n$); hàng dưới đếm số layer có trọng số của từng phần. Ở chế độ partial, stem, stage 1 và stage 2 (hộp thứ nhất đến thứ ba) bị đóng băng; classification head có 101 đầu ra.



Hình 6: Bottleneck block của ResNet-50 (ví dụ block thứ hai của stage 1, x có 256 kênh): ba convolution, mỗi convolution theo sau là BatchNorm (BN); đầu vào x được cộng vào đầu ra trước ReLU cuối. Ở block đầu của mỗi stage, nhánh residual connection là một convolution 1×1 kèm BatchNorm thay cho phép chép nguyên (identity).

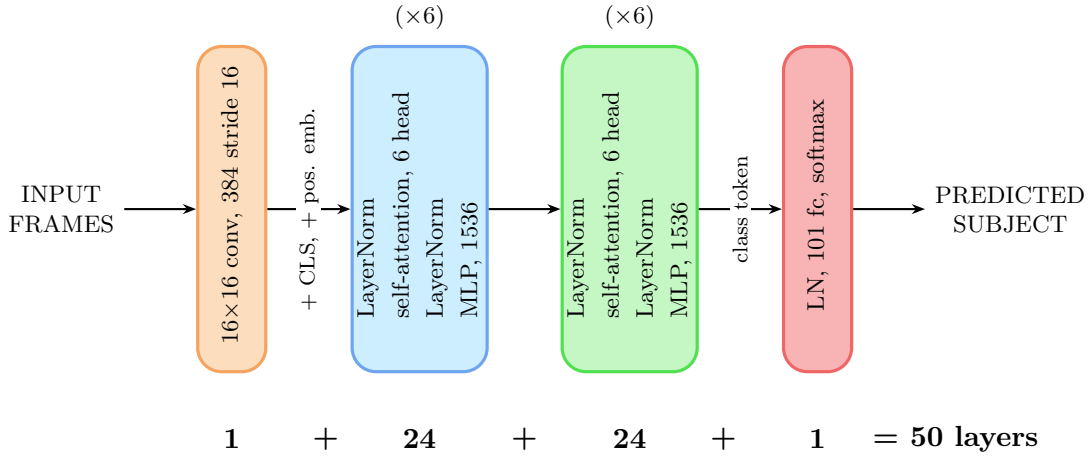
7.2 DeiT-S

DeiT-S (*Data-efficient image Transformer*, bản small) là một Vision Transformer cỡ nhỏ: 12 Transformer block, mỗi token 384 chiều, multi-head self-attention 6 head. Điểm mới của DeiT là cách huấn luyện giúp Transformer đạt accuracy tốt khi chỉ train trên ImageNet-1k. Ảnh 224×224 được chia thành 196 patch 16×16, mỗi patch được chiếu thành một token 384 chiều (*patch embedding*); thêm class token (CLS) và positional embedding, chuỗi 197 token đi qua 12 Transformer block với kích thước không đổi; cuối cùng class token qua LayerNorm và một fully connected layer cho ra 101 điểm số (Hình 7).

Các layer trong DeiT-S và chức năng của chúng:

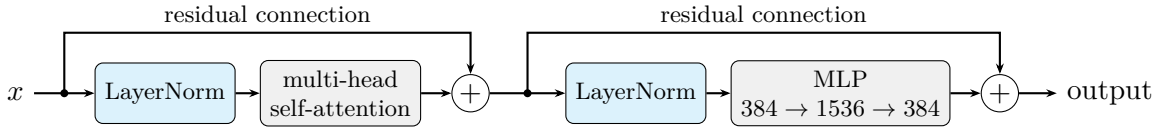
- **Patch embedding:** một convolution 16×16 stride 16, tương đương một linear projection, biến mỗi patch thành một vector 384 chiều (một token).
- **Class token (CLS) và positional embedding:** class token là một vector học được, thêm vào đầu chuỗi để gom thông tin của cả ảnh cho bước phân loại; positional embedding cộng vào từng token để mô hình biết mỗi patch nằm ở đâu.
- **Layer normalization (LayerNorm):** chuẩn hoá từng token theo chính các giá trị của token đó, không phụ thuộc batch.
- **Multi-head self-attention:** cho mỗi token lấy thông tin từ mọi token khác, với trọng số tuỳ mức độ liên quan; nhờ vậy một patch "nhìn" được toàn ảnh ngay từ block đầu. 6 head chạy song song, mỗi head có thể chú ý đến một kiểu quan hệ khác nhau.
- **MLP:** hai linear layer (384 lên 1536 rồi về 384) với activation function GELU, một phiên bản mềm của ReLU, xử lý riêng từng token.
- **Residual connection:** như ở ResNet-50, cộng đầu vào của mỗi phần vào đầu ra của nó.

- **Fully connected layer và softmax:** biến class token thành 101 điểm số (logit) rồi thành xác suất.



Hình 7: Kiến trúc DeiT-S: hộp đầu là patch embedding (chia ảnh thành 196 patch 16×16, chiếu mỗi patch thành 384 số); hai hộp giữa là 12 Transformer block giống nhau (×6 mỗi hộp); hộp cuối phân loại từ class token. Hàng dưới đếm các layer có trọng số (convolution và linear layer, không tính LayerNorm): mỗi block có 4 linear layer. Ở chế độ partial, patch embedding và 6 block đầu (hộp thứ nhất và thứ hai) bị đóng băng; classification head có 101 đầu ra.

Các layer này được ghép thành *Transformer block* (Hình 8): multi-head self-attention rồi MLP, mỗi phần có LayerNorm đứng trước và một residual connection.



Hình 8: Một Transformer block của DeiT-S (x là chuỗi 197 token × 384): LayerNorm đứng trước multi-head self-attention và MLP, và đầu vào của mỗi phần được cộng vào đầu ra của nó (residual connection).

8 Chế độ huấn luyện

Mỗi mô hình được huấn luyện theo bốn chế độ, khác nhau ở trọng số khởi tạo và phần mạng được cập nhật (Bảng 6). Hai mô hình nhân bốn chế độ thành 8 run, mỗi run train một lần với seed 42 trên toàn bộ tập train; dữ liệu, split, hàm loss và optimizer giống nhau ở cả bốn chế độ.

Chế độ	Khởi tạo	Phần được học	Epoch dự tính	ResNet-50 trainable	DeiT-S trainable
scratch	ngẫu nhiên	toàn bộ mạng	40	23 714 981 (100%)	21 704 549 (100%)
head	pretrained	chỉ classification head	10	206 949 (0.9%)	38 885 (0.2%)
partial	pretrained	nửa sau của mạng	15	22 270 053 (93.9%)	10 686 437 (49.2%)
full	pretrained	toàn bộ mạng	15	23 714 981 (100%)	21 704 549 (100%)

Bảng 6: Bốn chế độ huấn luyện, số epoch dự tính và số tham số được học.

Scratch (train từ đầu). Mô hình khởi tạo ngẫu nhiên, không dùng trọng số pretrained, và mọi tham số đều được học. Đây là mốc cho biết mô hình học được gì chỉ từ khoảng 68 000 ảnh Food-101, và dùng để đo pretrain giúp được bao nhiêu. Chế độ này có ngân sách epoch dài nhất (40 epoch) vì phải học mọi thứ từ đầu.

Head (chỉ train classification head). Mô hình nạp trọng số pretrained ImageNet-1k, classification head được thay bằng một linear layer 101 đầu ra khởi tạo ngẫu nhiên, và *chỉ layer này được học*; mọi phần còn lại bị đóng băng. Mô hình dùng nguyên các đặc trưng đã học từ ImageNet và chỉ học cách đọc chúng cho 101 món, nên chỉ có 0.9% (ResNet-50) và 0.2% (DeiT-S) số tham số được cập nhật. Đây là chế độ rẻ nhất và cho biết các đặc trưng pretrained đã tốt đến đâu với Food-101.

Partial (đóng băng nửa đầu). Mô hình nạp trọng số pretrained, nửa đầu của mạng (tính theo độ sâu) bị đóng băng, còn nửa sau và classification head được học. Nửa đầu giữ các đặc trưng cấp thấp như cạnh và kết cấu; nửa sau được điều chỉnh cho món ăn. Với ResNet-50, phần đóng băng gồm stem, stage 1 và stage 2; với DeiT-S, gồm patch embedding, class token, positional embedding và 6 Transformer block đầu. Vì ResNet-50 dồn tham số ở hai stage cuối còn 12 block của DeiT-S có cùng kích thước, cùng là "nửa đầu" nhưng ResNet-50 vẫn học 93.9% tham số còn DeiT-S học 49.2%.

Full (finetune toàn bộ). Mô hình nạp trọng số pretrained rồi cập nhật *mọi* tham số với learning rate nhỏ, nên các đặc trưng pretrained được điều chỉnh dần cho Food-101. Đây là cách dùng thông dụng nhất của pretrain và thường cho accuracy cao nhất, với chi phí tính toán bằng chế độ scratch trên mỗi epoch nhưng cần ít epoch hơn (15).

9 Đánh giá

Cả 8 run được đánh giá theo cùng một quy trình:

- **Chọn epoch và dùng test:** Sau mỗi epoch, mô hình được đánh giá trên validation (7 575 ảnh) và epoch có validation accuracy cao nhất được giữ lại (nếu bằng nhau thì lấy epoch sớm hơn). Sau khi train xong, checkpoint đó được đánh giá *đúng một lần* trên test (25 250 ảnh). Mọi quyết định khác, như kiểm tra learning rate hay chọn mô hình để phân tích lỗi, cũng chỉ dựa trên validation.
- **Chỉ số chất lượng:** Test accuracy là chỉ số chính. Ngoài ra báo cáo macro precision, recall và F1 (trung bình trên 101 lớp), accuracy của từng lớp, và validation accuracy tại epoch được giữ để so với test.
- **Chỉ số chi phí:** Số tham số được học, thời gian mỗi epoch, bộ nhớ GPU đỉnh khi train, và tốc độ suy luận (ảnh/giây).
- **Phân tích lỗi:** Trên mô hình CNN và mô hình Transformer có validation accuracy cao nhất, vẽ confusion matrix, liệt kê 15 cặp lớp bị nhầm nhiều nhất, và xem các ảnh bị đoán sai với độ tự tin cao nhất để biết đó là nhầm giữa các món giống nhau hay do nhãn sai.
- **Các so sánh:** Kết quả được đọc theo bốn nội dung ở Mục 2: (1) DeiT-S với ResNet-50 trong từng chế độ; (2) full với scratch cho từng mô hình, để đo pretrain giúp được bao nhiêu, và so mức tăng đó giữa hai mô hình; (3) head và partial với full cho từng mô hình, để đo accuracy mất đi khi đóng băng; (4) chi phí của từng cấu hình, đọc cạnh accuracy.