ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH




## HỌC SÂU VÀ ỨNG DỤNG TRONG THỊ GIÁC MÁY TÍNH (CO5085)

---

### Báo cáo Bài tập lớn A1

# CNN và Transformer trên tập ảnh lớn

---

| | | |
|---|---|---|
| GVHD: | TS. Lê Thành Sách | |
| | TS. Nguyễn Quốc Minh | |
| Sinh viên: | Lê Hữu Trọng | 2470578 |
| | Huỳnh Văn Tâm Thiện | 2470094 |

THÀNH PHỐ HỒ CHÍ MINH, THÁNG 10/2026

# Mục lục

**1 Giới thiệu** **2**

**2 Tập dữ liệu** **2**

2.1 Lựa chọn tập dữ liệu và lý do . . . . . 2

2.2 Giấy phép và nguồn . . . . . 3

2.3 Thống kê tập dữ liệu . . . . . 3

2.4 Phân chia tập dữ liệu . . . . . 3

2.5 Phân tích khám phá dữ liệu (EDA) . . . . . 4

**3 Chuẩn bị dữ liệu huấn luyện** **5**

3.1 Tiền xử lý . . . . . 5

3.2 Tăng cường dữ liệu . . . . . 5

3.3 Cấu hình DataLoader . . . . . 7

**4 Cài đặt thí nghiệm** **7**

4.1 Các mô hình . . . . . 7

4.1.1 ResNet-50 . . . . . 7

4.1.2 DeiT-S . . . . . 8

4.2 Các chế độ đóng băng . . . . . 10

4.3 Siêu tham số huấn luyện . . . . . 11

4.4 Độ đo đánh giá . . . . . 11

**5 Kết quả** **11**

**6 Phân tích** **11**

**7 Thảo luận và hạn chế** **11**

**8 Kết luận** **11**

**Tài liệu** **11**

# 1 Giới thiệu

Bài tập lớn A1 so sánh một mạng tích chập (CNN) và một Vision Transformer (ViT) trên một tập ảnh đủ lớn và đủ khó để khác biệt giữa hai họ kiến trúc, và giữa các cách dùng trọng số pretrained, có ý nghĩa. Bài chọn **Food-101** [1] (101 món ăn, 101 000 ảnh), **ResNet-50** [3] cho họ CNN và **DeiT-S** [4] cho họ Transformer. Mỗi mô hình được huấn luyện theo bốn chế độ: từ đầu (*scratch*), và ba cách dùng trọng số pretrained ImageNet-1k là chỉ train classification head (*head*), đóng băng nửa đầu mạng (*partial*) và finetune toàn bộ (*full*).

- **Tập dữ liệu.** Food-101, 101 lớp món ăn. Sau khi tách train, validation và test có 68 175, 7 575 và 25 250 ảnh (Mục 2).
- **Mô hình.** ResNet-50 (`microsoft/resnet-50`) cho CNN và DeiT-S (`facebook/deit-small-patch16-224`) cho Transformer, cả hai là bản công bố trên Hugging Face, có trọng số ImageNet-1k. Chế độ scratch không nạp trọng số đó (Mục 4.1).
- **Chế độ huấn luyện.** Train từ đầu (*scratch*), chỉ train classification head (*head*), đóng băng nửa đầu mạng (*partial*) và finetune toàn bộ (*full*). Hai mô hình nhân bốn chế độ thành 8 run, seed 42 (Mục 4.2).
- **Tiền xử lý.** Một pipeline tăng cường và chuẩn hoá, dùng chung cho mọi mô hình và mọi chế độ (Mục 3).

# 2 Tập dữ liệu

## 2.1 Lựa chọn tập dữ liệu và lý do

Food-101 [1] gồm 101 lớp món ăn, mỗi lớp 1 000 ảnh (750 ảnh train và 250 ảnh test theo split chính thức), cạnh dài nhất của ảnh không quá 512 px. Ảnh test đã được kiểm tra thủ công; ảnh train cố ý để nguyên nên còn nhiễu, chủ yếu là màu quá gắt và đôi khi sai nhãn. Food-101 được chọn vì bốn lý do:

- **Đủ lớn và đủ khó.** 101 lớp, 75 750 ảnh train chính thức; bài toán phân loại chi tiết, nhiều món khác nhau trông gần giống nhau.
- **Không trùng với ImageNet.** Tiny-ImageNet, Imagenette và các tập con của ImageNet bị loại vì ảnh của chúng nằm trong dữ liệu mà mô hình pretrained đã học, làm lệch so sánh scratch với pretrained.
- **Hợp với mô hình pretrained.** Ảnh tự nhiên, dùng được ở độ phân giải 224 px; CIFAR-100 ($32 \times 32$) phải phóng to gấp 7 lần nên bị loại.
- **Phù hợp ngân sách.** Khoảng 68 000 ảnh train đủ nhỏ để train từ đầu trên một GPU A10G.

Lưu ý: ImageNet-1k có sẵn một số lớp món ăn trùng hoặc gần với Food-101, nên trọng số pretrained có lợi thế ngữ nghĩa ở các lớp này.

## 2.2 Giấy phép và nguồn

Food-101 không có giấy phép mở: trên thẻ dữ liệu Hugging Face do nhóm tác giả ở ETH Zürich đăng, mục giấy phép ghi là không xác định (*unknown*). Ảnh được thu thập từ trang Foodspotting và thuộc về người đã đăng; theo mục *License Agreement* của thẻ dữ liệu, mọi cách dùng vượt quá phạm vi sử dụng hợp lý cho nghiên cứu khoa học (*scientific fair use*) phải thoả thuận với chủ ảnh. Bài tập chỉ dùng dữ liệu để học tập và nghiên cứu, không phân phối lại ảnh. Nguồn và điều khoản của Food-101 được ghi ở Bảng 1; dữ liệu được tải về qua thư viện torchvision.

| Hạng mục | Liên kết | Nội dung được dùng |
|---|---|---|
| Food-101 | huggingface.co/datasets/ethz/food101 | Thẻ mô tả do nhóm ETH Zürich đăng: 101 lớp, 750 ảnh train và 250 ảnh test mỗi lớp |
| Điều khoản sử dụng | huggingface.co/datasets/ethz/food101#license-agreement | Không có giấy phép mở. Dữ liệu chỉ được dùng để học và nghiên cứu |

**Bảng 1:** Nguồn và điều khoản sử dụng của Food-101.

## 2.3 Thống kê tập dữ liệu

Bảng 2 tóm tắt quy mô của tập dữ liệu; thống kê chi tiết hơn nằm ở Mục 2.5.

| Thuộc tính | Giá trị |
|---|---|
| Số lớp | 101 |
| Tổng số ảnh | 101 000 (75 750 train, 25 250 test) |
| Độ phân giải | cạnh dài 512 px, cạnh ngắn 122–512 px |
| Chế độ màu | 100 997 ảnh RGB, 3 ảnh xám |

**Bảng 2:** Thống kê tập dữ liệu.

## 2.4 Phân chia tập dữ liệu

Split test chính thức được giữ nguyên. Validation được tách từ split train chính thức: 10% mỗi lớp, phân tầng theo nhãn, seed 42 (Bảng 3). Split này cố định cho mọi run, ở cả hai mô hình và cả bốn chế độ, nên scratch và pretrained được so sánh trên cùng một split.

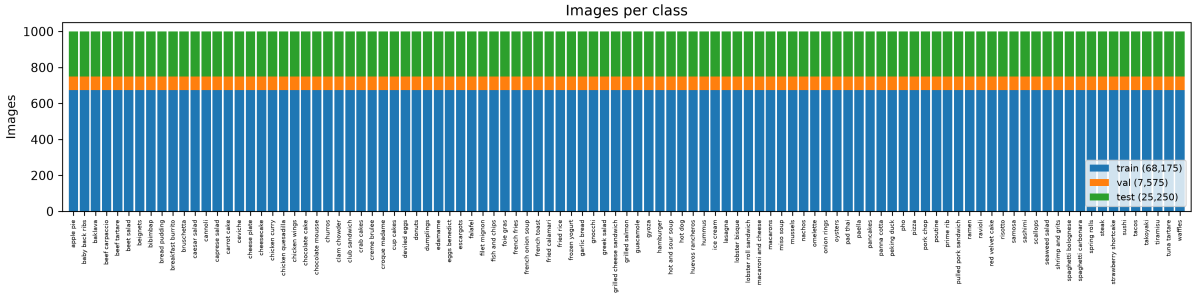
| Tập | Số ảnh | Ảnh/lớp | Nguồn |
|---|---|---|---|
| train | 68 175 | 675 | 90% split train chính thức |
| validation | 7 575 | 75 | 10% split train chính thức |
| test | 25 250 | 250 | split test chính thức |

**Bảng 3:** Ba tập dùng trong A1.

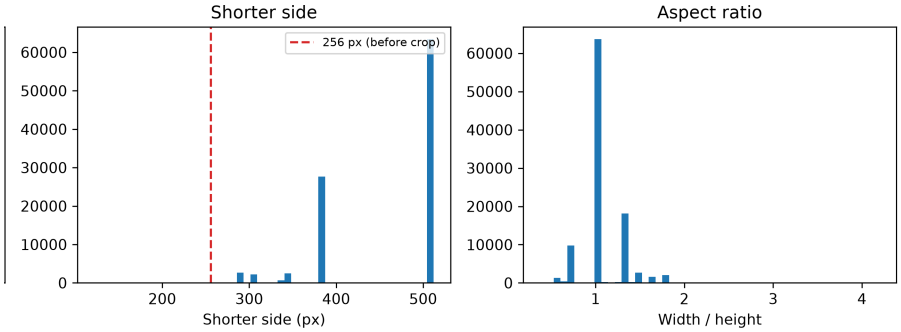
- **Test chỉ dùng một lần,** sau khi train xong; mọi quyết định (epoch giữ lại, learning rate) dựa trên validation.
- **Validation lấy từ train, không từ test,** để test không tham gia chọn mô hình.
- **Nhiễu nhãn:** validation lấy từ train nên cũng nhiễu, còn test đã được kiểm tra thủ công; validation accuracy vì vậy có thể thấp hơn test accuracy.

## 2.5 Phân tích khám phá dữ liệu (EDA)

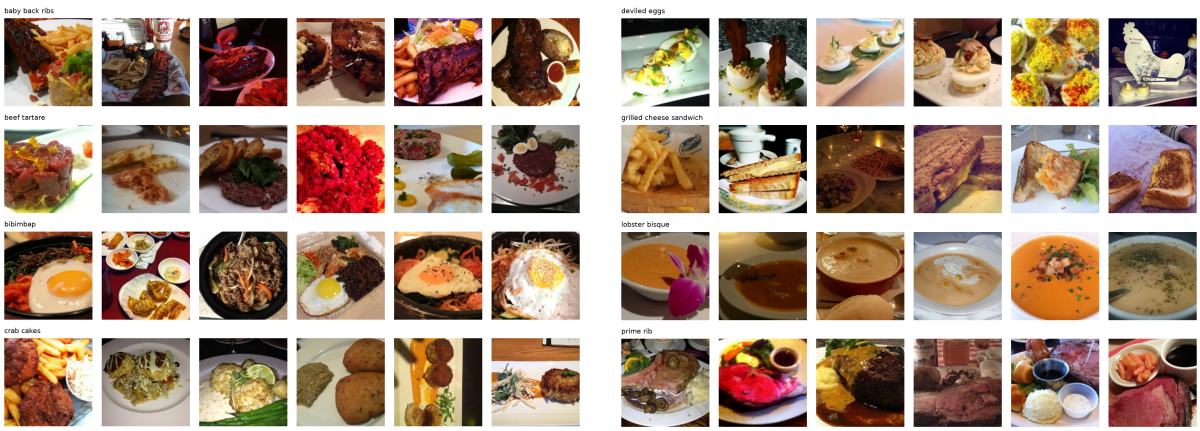
Kích thước ảnh được đo trên toàn bộ 101 000 ảnh gốc, trước khi thu nhỏ; mean và std theo kênh được tính trên toàn bộ 68 175 ảnh train, sau bước cắt cố định (Hình 1–3).




**Hình 1:** Số ảnh mỗi lớp trong train, validation và test.




**Hình 2:** Kích thước ảnh gốc. Trái: số ảnh theo độ dài cạnh ngắn (vạch đỏ là 256 px, mức đổi cạnh ngắn trước khi cắt). Phải: số ảnh theo tỉ lệ khung (rộng/cao).




**Hình 3:** Ảnh train của một số lớp, sau bước cắt cố định.

**Nhận xét:**

- **Cân bằng lớp.** Mỗi lớp có đúng 675 ảnh train, 75 ảnh validation và 250 ảnh test (Hình 1), nên không cần trọng số lớp.
- **Kích thước.** Cạnh dài luôn là 512 px. Theo Hình 2, khoảng 63% ảnh là ảnh vuông $512 \times 512$ và khoảng 27% có cạnh ngắn 384 px (khung 4:3); các tỉ lệ này đọc từ biểu đồ nên chỉ xấp xỉ. Chỉ 44 ảnh (0.04%) có cạnh ngắn dưới 256 px, được phóng lên khi đổi cạnh ngắn về 256 px, và quá ít để ảnh hưởng kết quả. Phép cắt giữa bỏ phần rìa của ảnh, đáng kể nhất với ảnh có khung dài (tỉ lệ đến 4.2), nhưng các ảnh này rất hiếm.
- **Chế độ màu.** 100 997 ảnh RGB và 3 ảnh xám (chuyển sang RGB khi tiền xử lý).
- **Màu sắc.** Mean RGB là $(0.557, 0.442, 0.327)$, std khoảng 0.26: ảnh món ăn nghiêng về đỏ hơn ImageNet $(0.485, 0.456, 0.406)$.
- **Nhiễu nhãn** (Hình 3). Ảnh chụp trong nhà hàng nên ánh sáng, góc chụp và nền rất khác nhau. Trong 48 ảnh mẫu có ít nhất hai ảnh mà nhãn không ứng với chủ thể rõ ràng (ảnh thứ hai của *bibimbap* chủ yếu là há cảo; ảnh thứ ba của *grilled cheese sandwich* không thấy bánh) và vài ảnh có màu rất gắt, đúng như tác giả mô tả. Mẫu quá nhỏ để ước lượng tỉ lệ nhiễu.
- **Cặp lớp dễ nhầm**: các món gần nhau như *prime rib*, *steak*; sẽ được đo bằng ma trận nhầm lẫn (Mục 4.4).

# 3 Chuẩn bị dữ liệu huấn luyện

## 3.1 Tiền xử lý

Mọi mô hình và mọi chế độ dùng chung một pipeline dữ liệu, các run chỉ khác nhau ở mô hình và cách huấn luyện, không khác ở dữ liệu đưa vào.

**Cắt cố định, áp dụng một lần cho mọi ảnh.** Mọi ảnh của cả ba tập (train, validation, test) được xử lý đúng một lần theo cùng một cách: chuyển sang RGB, đổi cạnh ngắn về 256 px, rồi cắt phần giữa $224 \times 224$ và lưu lại dạng JPEG.

**Chuẩn hoá.** Ảnh được đưa về tensor trong $[0, 1]$ rồi chuẩn hoá với mean $(0.485, 0.456, 0.406)$ và std $(0.229, 0.224, 0.225)$ của ImageNet, đúng thống kê mà cả hai bộ trọng số pretrained được train. Chọn thống kê này cho mọi run, kể cả scratch, để đầu vào của phần mạng bị đóng băng ở chế độ head và partial có cùng thang đo như lúc pretrain; nếu dùng thang đo khác, BatchNorm đóng băng của ResNet-50 sẽ chuẩn hoá bằng thống kê không còn khớp, còn LayerNorm của DeiT-S thì tự điều chỉnh, làm lệch phép so sánh hai họ kiến trúc.

## 3.2 Tăng cường dữ liệu

Sau bước đó, chỉ tập train được tăng cường dữ liệu (Bảng 4, Hình 4); validation và test chỉ được chuẩn hoá.

| Bước | Train | Validation, test và tập train dùng để đánh giá |
|---|---|---|
| Cắt cố định (một lần, mọi ảnh) | Đổi cạnh ngắn về 256 px, cắt giữa $224 \times 224$ | như train |
| Lật | Lật ngang với xác suất 0.5 | – |
| Xoay | Xoay ngẫu nhiên trong khoảng $\pm 15°$ | – |
| Màu | Độ sáng, tương phản, độ bão hoà đổi trong $\pm 20\%$; sắc độ xoay trong $\pm 0.1$ vòng màu ($\pm 36°$) | – |
| Dịch | Dịch ngẫu nhiên tối đa 10% theo mỗi chiều | – |
| Chuẩn hoá | Đưa về tensor trong $[0, 1]$, rồi trừ mean và chia std của ImageNet trên từng kênh | như train |

**Bảng 4:** Pipeline dữ liệu dùng chung, theo đúng thứ tự áp dụng.




**Hình 4:** Minh hoạ tăng cường dữ liệu.

### 3.3 Cấu hình DataLoader

# 4 Cài đặt thí nghiệm

## 4.1 Các mô hình

Cả hai mô hình có cùng một khung: một **feature extractor** biến ảnh thành một vector đặc trưng mô tả nội dung ảnh, và một **classification head** biến vector đó thành 101 điểm số, mỗi điểm cho một món. Khác nhau ở feature extractor: ResNet-50 là mạng tích chập, quét ảnh bằng các filter nhỏ và thu nhỏ ảnh dần qua từng stage; DeiT-S là Transformer, cắt ảnh thành các patch rồi cho mọi patch trao đổi thông tin với nhau bằng self-attention. Mục 4.1.1 và 4.1.2 trình bày cấu trúc của từng mô hình và chức năng của các layer trong đó.

Hai mô hình dùng trọng số công bố trên Hugging Face (Bảng 5), có số tham số và chi phí tính toán gần nhau, và cùng được pretrain chỉ trên ImageNet-1k để nguồn pretrain không làm lệch so sánh. Classification head được thay bằng một linear layer 101 đầu ra, khởi tạo ngẫu nhiên. Số tham số và kích thước đầu ra dưới đây được đo trực tiếp trên mô hình.

| Họ | Mô hình | Tham số (M) | FLOPs (G) | Nguồn pretrained |
|---|---|---|---|---|
| CNN | ResNet-50 | 23.7 | 8.2 | `microsoft/resnet-50` (ImageNet-1k) |
| Transformer | DeiT-S | 21.7 | 9.2 | `facebook/deit-small-patch16-224` (ImageNet-1k) |

**Bảng 5:** Các mô hình sử dụng.

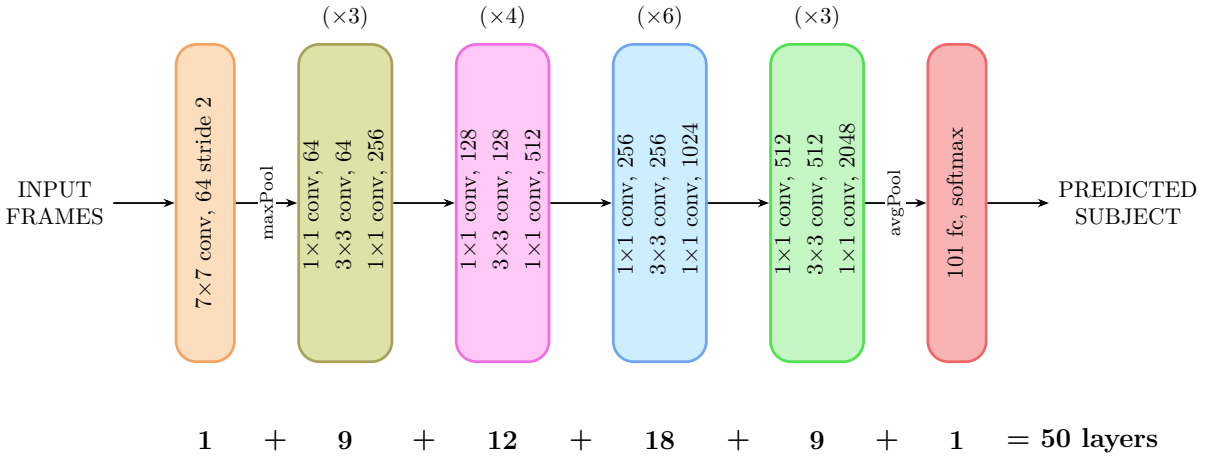
### 4.1.1 ResNet-50

ResNet-50 [3] gồm một *stem* (convolution $7 \times 7$ và max pooling, thu ảnh từ $224 \times 224$ xuống $56 \times 56$), bốn *stage* gồm 3, 4, 6 và 3 *bottleneck block*, rồi global average pooling và một fully connected layer 101 đầu ra (Hình 5). Từ stage 2, mỗi stage giảm kích thước ảnh một nửa (còn 28, 14, rồi 7) và tăng gấp đôi số kênh (từ 256 lên 2048).

Các layer trong ResNet-50 và chức năng:

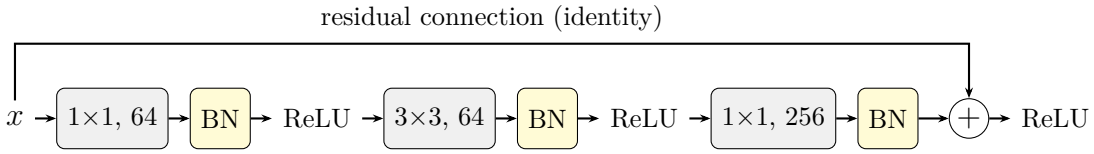
- **Convolution:** trượt các filter nhỏ trên ảnh để phát hiện đặc trưng cục bộ như cạnh, màu, kết cấu; convolution có stride 2 làm ảnh nhỏ đi một nửa.
- **Max pooling:** giữ giá trị lớn nhất trong mỗi vùng $3 \times 3$, dùng ở stem để thu nhỏ ảnh một nửa.
- **Batch normalization (BatchNorm):** đặt sau mỗi convolution, chuẩn hoá từng kênh theo trung bình và độ lệch chuẩn của cả batch, giúp train ổn định và nhanh hơn.
- **ReLU (activation function):** hàm kích hoạt phi tuyến, giữ số dương và đặt số âm về 0; thiếu nó, cả mạng chỉ là một phép biến đổi tuyến tính.
- **Residual connection** (*skip connection*): cộng đầu vào của block vào đầu ra, để block chỉ cần học phần thay đổi; nhờ vậy mạng 50 layer vẫn train được.

- **Global average pooling:** lấy trung bình mỗi kênh trên toàn ảnh, biến feature map $2048 \times 7 \times 7$ thành một vector 2048 số.
- **Fully connected layer và softmax:** fully connected layer biến vector 2048 số thành 101 điểm số (logit); softmax đổi chúng thành xác suất của 101 món.




**Hình 5:** Kiến trúc ResNet-50: mỗi hộp là một stage, ghi các convolution của một bottleneck block và số lần lặp ($\times n$); hàng dưới đếm số layer có trọng số của từng phần. Ở chế độ partial, stem, stage 1 và stage 2 (hộp thứ nhất đến thứ ba) bị đóng băng; classification head có 101 đầu ra.

Các layer này được ghép thành *bottleneck block* (Hình 6): convolution $1 \times 1$ đầu giảm số kênh (ví dụ 256 xuống 64) để convolution $3 \times 3$ giảm khối lượng tính toán, rồi convolution $1 \times 1$ cuối tăng lại gấp 4; ở block đầu mỗi stage, residual connection dùng thêm một convolution $1 \times 1$ (*projection shortcut*) để khớp kích thước.



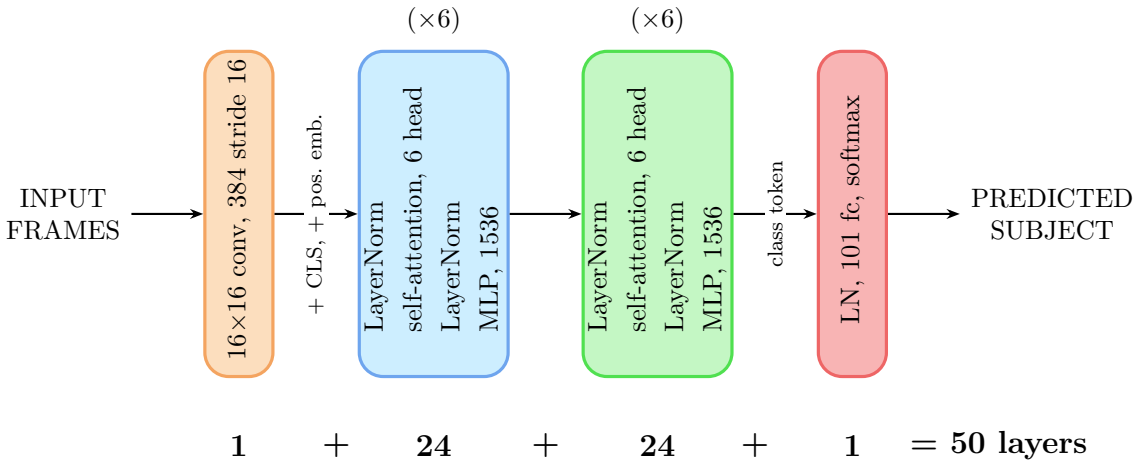

**Hình 6:** Bottleneck block của ResNet-50 (ví dụ block thứ hai của stage 1, $x$ có 256 kênh): ba convolution, mỗi convolution theo sau là BatchNorm (BN); đầu vào $x$ được cộng vào đầu ra trước ReLU cuối. Ở block đầu của mỗi stage, nhánh residual connection là một convolution $1 \times 1$ kèm BatchNorm thay cho phép chép nguyên (identity).

### 4.1.2 DeiT-S

DeiT-S (*Data-efficient image Transformer*, bản small) là một Vision Transformer [2] cỡ nhỏ [4]: 12 Transformer block, mỗi token 384 chiều, multi-head self-attention 6 head. Điểm mới của DeiT là cách huấn luyện giúp Transformer đạt accuracy tốt khi chỉ train trên ImageNet-1k. Ảnh $224 \times 224$ được chia thành 196 patch $16 \times 16$, mỗi patch được chiếu thành một token 384 chiều (*patch embedding*); thêm class token (CLS) và positional embedding, chuỗi 197 token đi qua 12 Transformer block với kích thước không đổi; cuối cùng class token qua LayerNorm và một fully connected layer cho ra 101 điểm số (Hình 7).

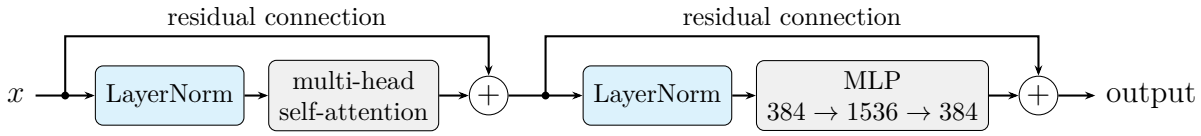
Các layer trong DeiT-S và chức năng của chúng:

- **Patch embedding:** một convolution $16 \times 16$ stride 16, tương đương một linear projection, biến mỗi patch thành một vector 384 chiều (một token).
- **Class token (CLS) và positional embedding:** class token là một vector học được, thêm vào đầu chuỗi để gom thông tin của cả ảnh cho bước phân loại; positional embedding cộng vào từng token để mô hình biết mỗi patch nằm ở đâu.
- **Layer normalization (LayerNorm):** chuẩn hoá từng token theo chính các giá trị của token đó, không phụ thuộc batch.
- **Multi-head self-attention:** cho mỗi token lấy thông tin từ mọi token khác, với trọng số tuỳ mức độ liên quan; nhờ vậy một patch nhìn được toàn ảnh ngay từ block đầu. 6 head chạy song song, mỗi head có thể chú ý đến một kiểu quan hệ khác nhau.
- **MLP:** hai linear layer (384 lên 1536 rồi về 384) với activation function GELU, một phiên bản mềm của ReLU, xử lý riêng từng token.
- **Residual connection:** như ở ResNet-50, cộng đầu vào của mỗi phần vào đầu ra của nó.
- **Fully connected layer và softmax:** biến class token thành 101 điểm số (logit) rồi thành xác suất.




**Hình 7:** Kiến trúc DeiT-S: hộp đầu là patch embedding (chia ảnh thành 196 patch 16×16, chiếu mỗi patch thành 384 số); hai hộp giữa là 12 Transformer block giống nhau (×6 mỗi hộp); hộp cuối phân loại từ class token. Hàng dưới đếm các layer có trọng số (convolution và linear layer, không tính LayerNorm): mỗi block có 4 linear layer. Ở chế độ partial, patch embedding và 6 block đầu (hộp thứ nhất và thứ hai) bị đóng băng; classification head có 101 đầu ra.

Các layer này được ghép thành *Transformer block* (Hình 8): multi-head self-attention rồi MLP, mỗi phần có LayerNorm đứng trước và một residual connection.




**Hình 8:** Một Transformer block của DeiT-S ($x$ là chuỗi 197 token × 384): LayerNorm đứng trước multi-head self-attention và MLP, và đầu vào của mỗi phần được cộng vào đầu ra của nó (residual connection).

## 4.2 Các chế độ đóng băng

Mỗi mô hình được huấn luyện theo bốn chế độ, khác nhau ở trọng số khởi tạo và phần mạng được cập nhật (Bảng 6). Hai mô hình nhân bốn chế độ thành 8 run, mỗi run train một lần với seed 42 trên toàn bộ tập train; dữ liệu, split, hàm loss và optimizer giống nhau ở cả bốn chế độ.

| Chế độ | Khởi tạo | Phần được học | Epoch dự tính | ResNet-50 trainable | DeiT-S trainable |
|---|---|---|---|---|---|
| scratch | ngẫu nhiên | toàn bộ mạng | 40 | 23 714 981 (100%) | 21 704 549 (100%) |
| head | pretrained | chỉ classification head | 15 | 206 949 (0.9%) | 38 885 (0.2%) |
| partial | pretrained | nửa sau của mạng | 15 | 22 270 053 (93.9%) | 10 686 437 (49.2%) |
| full | pretrained | toàn bộ mạng | 15 | 23 714 981 (100%) | 21 704 549 (100%) |

**Bảng 6:** Bốn chế độ huấn luyện, số epoch dự tính và số tham số được học.

**Scratch (train từ đầu).** Mô hình khởi tạo ngẫu nhiên, không dùng trọng số pretrained, và mọi tham số đều được học. Đây là mốc cho biết mô hình học được gì chỉ từ khoảng 68 000 ảnh Food-101, và dùng để đo pretrain giúp được bao nhiêu. Chế độ này có epoch dài nhất (40 epoch) vì phải học mọi thứ từ đầu.

**Head (chỉ train classification head).** Mô hình nạp trọng số pretrained ImageNet-1k, classification head được thay bằng một linear layer 101 đầu ra khởi tạo ngẫu nhiên, và *chỉ layer này được học*; mọi phần còn lại bị đóng băng. Mô hình dùng nguyên các đặc trưng đã học từ ImageNet và chỉ học cách đọc chúng cho 101 món, nên chỉ có 0.9% (ResNet-50) và 0.2% (DeiT-S) số tham số được cập nhật. Đây là chế độ rẻ nhất và cho biết các đặc trưng pretrained đã tốt đến đâu với Food-101.

**Partial (đóng băng nửa đầu).** Mô hình nạp trọng số pretrained, nửa đầu của mạng (tính theo độ sâu) bị đóng băng, còn nửa sau và classification head được học. Nửa đầu giữ các đặc trưng cấp thấp như cạnh và kết cấu; nửa sau được điều chỉnh cho món ăn. Với ResNet-50, phần đóng băng gồm stem, stage 1 và stage 2; với DeiT-S, gồm patch embedding, class token, positional embedding và 6 Transformer block đầu. Vì ResNet-50 dồn tham số ở hai stage cuối còn 12 block của DeiT-S có cùng kích thước, cùng là nửa đầu nhưng ResNet-50 vẫn học 93.9% tham số còn DeiT-S học 49.2%.

**Full (finetune toàn bộ).** Mô hình nạp trọng số pretrained rồi cập nhật *mọi* tham số với learning rate nhỏ, nên các đặc trưng pretrained được điều chỉnh dần cho Food-101. Đây là cách dùng thông dụng nhất của pretrain và thường cho accuracy cao nhất, với chi phí tính toán bằng chế độ scratch trên mỗi epoch nhưng cần ít epoch hơn (15).

### 4.3 Siêu tham số huấn luyện

### 4.4 Độ đo đánh giá

Cả 8 run được đánh giá theo cùng một quy trình:

- **Chọn epoch và dùng test:** Sau mỗi epoch, mô hình được đánh giá trên validation (7 575 ảnh) và epoch có validation accuracy cao nhất được giữ lại (nếu bằng nhau thì lấy epoch sớm hơn). Sau khi train xong, checkpoint đó được đánh giá *đúng một lần* trên test (25 250 ảnh). Mọi quyết định khác, như kiểm tra learning rate hay chọn mô hình để phân tích lỗi, cũng chỉ dựa trên validation.
- **Chỉ số chất lượng:** Test accuracy là chỉ số chính. Ngoài ra báo cáo macro precision, recall và F1 (trung bình trên 101 lớp), accuracy của từng lớp, và validation accuracy tại epoch được giữ để so với test.
- **Chỉ số chi phí:** Số tham số được học, thời gian mỗi epoch, bộ nhớ GPU đỉnh khi train, và tốc độ suy luận (ảnh/giây).
- **Phân tích lỗi:** Trên mô hình CNN và mô hình Transformer có validation accuracy cao nhất, vẽ confusion matrix, liệt kê 15 cặp lớp bị nhầm nhiều nhất, và xem các ảnh bị đoán sai với độ tự tin cao nhất để biết đó là nhầm giữa các món giống nhau hay do nhãn sai.
- **Các so sánh:** Kết quả được đọc theo bốn nội dung: (1) DeiT-S với ResNet-50 trong từng chế độ; (2) full với scratch cho từng mô hình, để đo pretrain giúp được bao nhiêu, và so mức tăng đó giữa hai mô hình; (3) head và partial với full cho từng mô hình, để đo accuracy mất đi khi đóng băng; (4) chi phí của từng cấu hình, đọc cạnh accuracy.

# 5 Kết quả

# 6 Phân tích

# 7 Thảo luận và hạn chế

# 8 Kết luận

# Tài liệu

[1] Lukas Bossard, Matthieu Guillaumin, and Luc Van Gool. Food-101 – mining discriminative components with random forests. In *European Conference on Computer Vision (ECCV)*, pages 446–461, 2014.

[2] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold,

Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations (ICLR)*, 2021.

[3] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.

[4] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Hervé Jégou. Training data-efficient image transformers & distillation through attention. In *International Conference on Machine Learning (ICML)*, pages 10347–10357, 2021.