ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



HỌC SÂU VÀ ỨNG DỤNG TRONG THỊ GIÁC MÁY TÍNH (CO5085)

Báo cáo Bài tập E1–E3

GVHD: TS. Lê Thành Sách
TS. Nguyễn Quốc Minh
Sinh viên: Lê Hữu Trọng 2470578
Huỳnh Văn Tâm Thiện 2470094

THÀNH PHỐ HỒ CHÍ MINH, THÁNG 11/2026

Mục lục

1 Giới thiệu **2**

2 Dữ liệu và phương pháp đánh giá **2**

2.1 Tập dữ liệu và cách chia 2

2.2 Tiền xử lý và tăng cường dữ liệu 4

2.3 Phương pháp đánh giá 5

2.4 Khả năng tái lập 6

3 E1: Softmax, MLP và CNN **6**

3.1 Mô hình 6

3.2 Thiết lập huấn luyện 7

3.3 Kết quả và phân tích 7

3.4 Thảo luận 10

4 E2: Transformer – MSA và các cách tạo token **12**

4.1 Mô hình 12

4.2 Thiết lập huấn luyện 14

4.3 Kết quả và phân tích 15

4.4 Thảo luận 17

5 E3: LSTM và GRU trên chuỗi ảnh **20**

5.1 Mô hình 20

5.2 Thiết lập huấn luyện 20

5.3 Kết quả và phân tích 21

5.4 Thảo luận 23

6 Kết luận **23**

Tài liệu **24**

1 Giới thiệu

Báo cáo này khảo sát và so sánh hiệu suất của các mô hình học sâu thông qua ba bài tập E1–E3. Để đối chiếu trực tiếp các phương pháp, chúng tôi dùng chung một tập ảnh nhỏ cho cả ba bài. Toàn bộ mã nguồn, tài liệu và kết quả chi tiết của các thực nghiệm được công khai tại các địa chỉ sau:

- GitHub Repository: `https://github.com/tronglh241/co5085_dl4cv`
- GitHub Pages: `https://tronglh241.github.io/co5085_dl4cv`

Nội dung chính của các bài tập được triển khai như sau:

- **Bài E1 (Mục 3):** So sánh ba bộ phân loại cơ bản gồm Softmax, Multilayer Perceptron (MLP) và Convolutional Neural Network (CNN), được đánh giá trong cả hai trường hợp có và không có kỹ thuật tăng cường dữ liệu.
- **Bài E2 (Mục 4):** Xây dựng bộ phân loại dựa trên cơ chế Multi-Head Self-Attention (MSA), trong đó, chúng tôi hiện thực MSA từ đầu để đối chiếu với module sẵn có của PyTorch, đồng thời khảo sát các phương pháp chuyển đổi ảnh thành chuỗi token khác nhau.
- **Bài E3 (Mục 5):** Xem xét ảnh dưới góc độ dữ liệu chuỗi để huấn luyện các mô hình hồi quy Long Short-Term Memory (LSTM) và Gated Recurrent Unit (GRU), sau đó so sánh kết quả với các mô hình không hồi quy đã khảo sát ở bài E1.

Mục tiêu của báo cáo không dừng lại ở việc liệt kê accuracy của từng mô hình, mà tập trung giải thích nguyên nhân dẫn đến sự khác biệt về hiệu suất thông qua số lượng tham số, đường cong học và phân tích chi tiết các trường hợp phân loại sai.

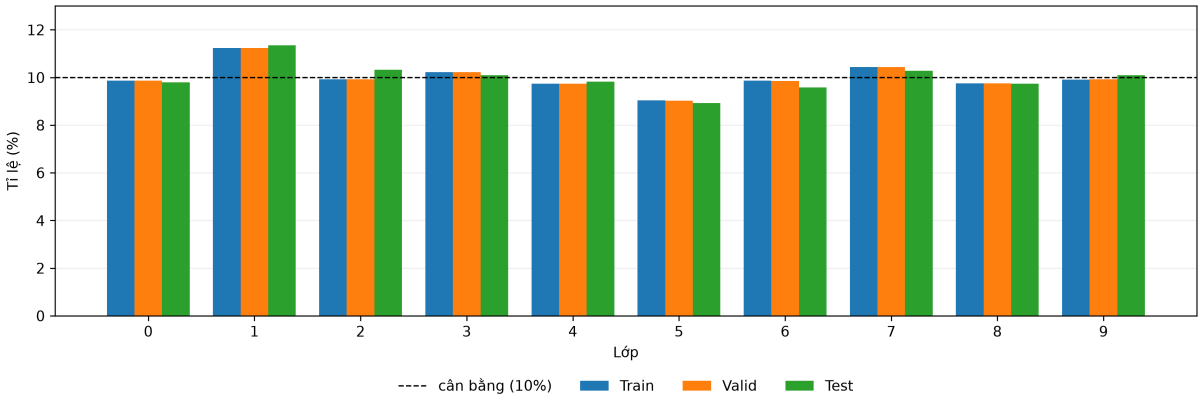
Phần còn lại của báo cáo được tổ chức như sau. Mục 2 mô tả dữ liệu, phương pháp tiền xử lý và đánh giá dùng chung cho cả ba bài. Các Mục 3, 4 và 5 lần lượt trình bày bài E1, E2 và E3, mỗi mục gồm mô hình, thiết lập huấn luyện riêng, kết quả và thảo luận. Mục 6 tổng hợp những kết luận của các bài E1, E2 và E3.

2 Dữ liệu và phương pháp đánh giá

2.1 Tập dữ liệu và cách chia

Trong báo cáo này, chúng tôi sử dụng MNIST [3], tập dữ liệu chuẩn gồm các ảnh chữ số viết tay dạng ảnh xám với kích thước 28×28 điểm ảnh, gồm 10 lớp từ 0 đến 9. Bộ dữ liệu gốc bao gồm 60 000 ảnh huấn luyện và 10 000 ảnh kiểm thử chính thức (test). Việc lựa chọn MNIST dựa trên ba lý do chính:

- **Tốc độ huấn luyện:** Kích thước ảnh nhỏ và chỉ có một kênh màu giúp rút ngắn thời gian huấn luyện, tạo điều kiện thử nghiệm nhiều biến thể cấu trúc.



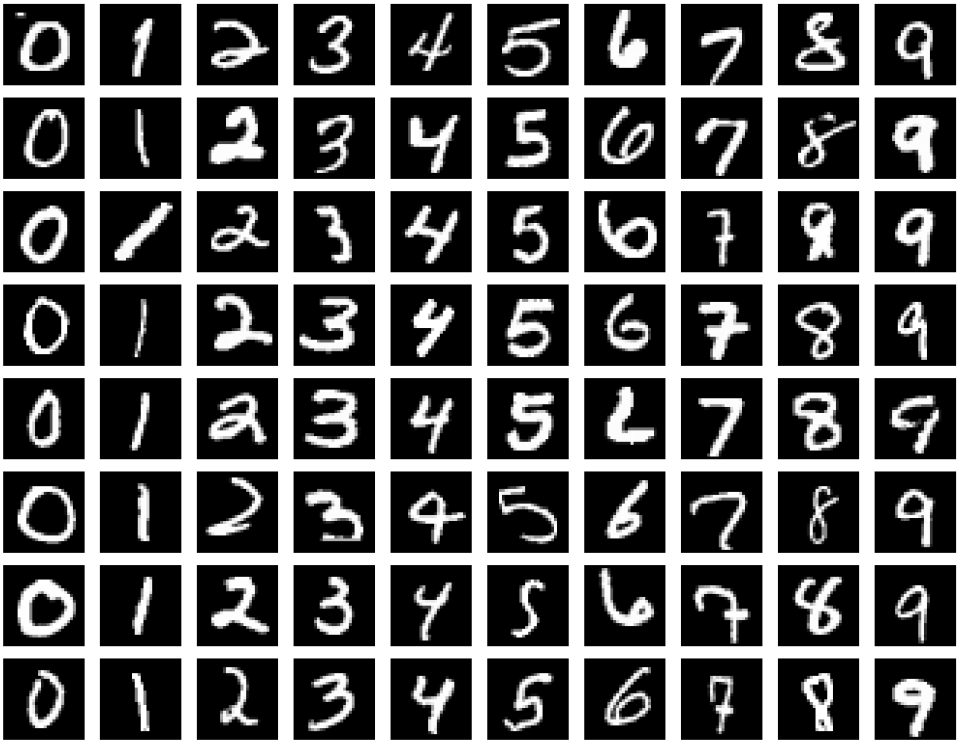
Hình 1: Biểu đồ thể hiện sự phân bố mẫu dữ liệu giữa các lớp trong tập dữ liệu MNIST, minh họa tính cân bằng dữ liệu.

Bảng 1: Số lượng ảnh của từng lớp trong các tập dữ liệu.

Lớp	Train	Valid	Test
0	4 936	987	980
1	5 618	1 124	1 135
2	4 965	993	1 032
3	5 109	1 022	1 010
4	4 868	974	982
5	4 518	903	892
6	4 932	986	958
7	5 221	1 044	1 028
8	4 876	975	974
9	4 957	992	1 009
Tổng	50 000	10 000	10 000

- **Tính chuẩn hóa:** Là một bộ dữ liệu tham chiếu phổ biến, MNIST giúp dễ dàng đối chiếu, so sánh kết quả của các mô hình.
- **Sự cân bằng dữ liệu:** Các lớp trong MNIST có phân bố số lượng tương đối đồng đều, giúp độ đo accuracy phản ánh trung thực hiệu suất tổng thể của mô hình mà không bị ảnh hưởng bởi hiện tượng mất cân bằng lớp.

Từ 60 000 ảnh huấn luyện gốc, chúng tôi tách thành 50 000 ảnh cho tập huấn luyện (train) và 10 000 ảnh cho tập kiểm định (valid) theo phương pháp phân tầng (stratified splitting) để duy trì tỷ lệ các lớp đồng đều giữa các tập. Quá trình chia dữ liệu được thực hiện duy nhất một lần nhằm đảm bảo mọi mô hình trong các bài tập E1, E2 và E3 đều được huấn luyện và đánh giá trên cùng một tập dữ liệu. Tập test chính thức được giữ nguyên hoàn toàn tách biệt khỏi quá trình huấn luyện. Số lượng ảnh của từng lớp được thể hiện trong Bảng 1, phân bố của các lớp được thể hiện trong Hình 1, trong khi Hình 2 minh họa một số mẫu dữ liệu từ các lớp khác nhau.



Hình 2: Một số ảnh mẫu từ tập dữ liệu MNIST.

2.2 Tiền xử lý và tăng cường dữ liệu

Trước khi đưa vào mô hình, mỗi ảnh được chuyển thành tensor với giá trị điểm ảnh nằm trong khoảng $[0, 1]$, sau đó được chuẩn hóa dựa trên giá trị trung bình và độ lệch chuẩn được tính trên tập train:

$$\tilde{x} = \frac{x - 0{,}1308}{0{,}3082} \tag{1}$$

Bước chuẩn hóa này đưa đầu vào về phân phối có trung bình gần 0 và độ lệch chuẩn gần 1, giúp quá trình tối ưu hóa trọng số diễn ra ổn định hơn. Đây là phương pháp tiền xử lý cơ bản được áp dụng xuyên suốt cho tất cả các mô hình.

Trong các thí nghiệm có sử dụng tăng cường dữ liệu, chúng tôi bổ sung phép biến đổi `RandomAffine(10, translate=(0.1, 0.1))` vào dữ liệu train. Phép biến đổi này xoay ảnh một góc ngẫu nhiên trong khoảng $[-10°, 10°]$ và tịnh tiến ngẫu nhiên tối đa 10% kích thước ảnh theo mỗi chiều, tương đương khoảng 2,8 điểm ảnh. Phép biến đổi được áp dụng theo hình thức trực tuyến: mỗi khi một ảnh được nạp từ tập train, các tham số xoay và dịch chuyển được sinh ngẫu nhiên lại, điều này giúp mô hình tiếp cận các biến thể khác nhau của cùng một mẫu ở mỗi epoch. Bảng 2 tóm tắt quy trình tiền xử lý, trong khi Hình 3 minh họa kết quả thực tế của phép tăng cường.

Kỹ thuật tăng cường dữ liệu chỉ được thực hiện trên các batch dùng để cập nhật trọng số trong quá trình huấn luyện. Khi tiến hành đánh giá, toàn bộ dữ liệu ở cả ba tập train, valid và test đều được đưa vào mô hình dưới dạng ảnh gốc. Nhờ vậy, mọi chỉ số đánh giá trong báo cáo đều được đo lường trên dữ liệu sạch, đảm bảo tính khách quan khi so sánh



Hình 3: Ảnh gốc và các phiên bản sau khi áp dụng `RandomAffine(10, translate=(0.1, 0.1))`.

Bảng 2: Quy trình tiền xử lý áp dụng cho dữ liệu train.

Bước	Phép biến đổi	Không tăng cường	Có tăng cường
1	`RandomAffine(10, translate=(0.1, 0.1))`	không	có
2	`ToTensor()`	có	có
3	`Normalize(0.1308, 0.3082)`	có	có

giữa các thiết lập thí nghiệm.

2.3 Phương pháp đánh giá

Quy trình đánh giá Ba tập dữ liệu đóng các vai trò độc lập trong quá trình thực nghiệm:

- **Tập train** được sử dụng trực tiếp để cập nhật trọng số của mô hình.
- **Tập valid** hỗ trợ theo dõi tiến trình huấn luyện, điều chỉnh tốc độ học, quyết định thời điểm dừng sớm và lựa chọn checkpoint tốt nhất.
- **Tập test** chỉ được sử dụng một lần duy nhất ở giai đoạn cuối trên checkpoint đã được chọn qua tập valid, đảm bảo kết quả đánh giá cuối cùng không bị ảnh hưởng bởi quá trình tinh chỉnh mô hình.

Chi tiết về điều chỉnh tốc độ học, điều kiện dừng và tiêu chí chọn checkpoint cho từng bài tập cụ thể sẽ được trình bày ở phần thiết lập huấn luyện tương ứng.

Độ đo hiệu suất Gọi $K = 10$ là tổng số lớp và C_{ij} là số lượng mẫu thuộc lớp thật i nhưng được mô hình dự đoán thành lớp j. Độ đo chính của báo cáo là accuracy, phản ánh tỷ lệ mẫu được phân loại đúng:

$$\text{accuracy} = \frac{\sum_{c=1}^{K} C_{cc}}{\sum_{i=1}^{K} \sum_{j=1}^{K} C_{ij}}. \tag{2}$$

Bên cạnh đó, chúng tôi phân tích tổng số ảnh bị phân loại sai, ma trận nhầm lẫn và các mẫu lỗi cụ thể để giải thích sự khác biệt giữa các mô hình.

Nguyên tắc so sánh công bằng Để đảm bảo tính khách quan, các yếu tố ngoài kiến trúc mô hình đều được cố định:

- Tất cả mô hình sử dụng chung một tập dữ liệu đã chia ở Mục 2.1 và chuỗi tiền xử lý ở Mục 2.2.
- Trong cùng một bài tập, các mô hình sử dụng cùng một thuật toán tối ưu hóa, tốc độ học ban đầu, bộ lập lịch, tiêu chí dừng và seed khởi tạo. Các biến thể không tăng cường và có tăng cường chỉ khác biệt duy nhất ở bước áp dụng `RandomAffine`.
- Việc tinh chỉnh siêu tham số chỉ dựa trên tập valid, tuyệt đối không dùng tập test để lựa chọn mô hình.

Dù thiết lập huấn luyện có thể khác biệt giữa ba bài E1, E2 và E3 nhằm phù hợp với đặc thù của từng họ kiến trúc, nhưng các điều kiện vẫn được đảm bảo luôn giữ đồng nhất trong phạm vi từng bài.

2.4 Khả năng tái lập

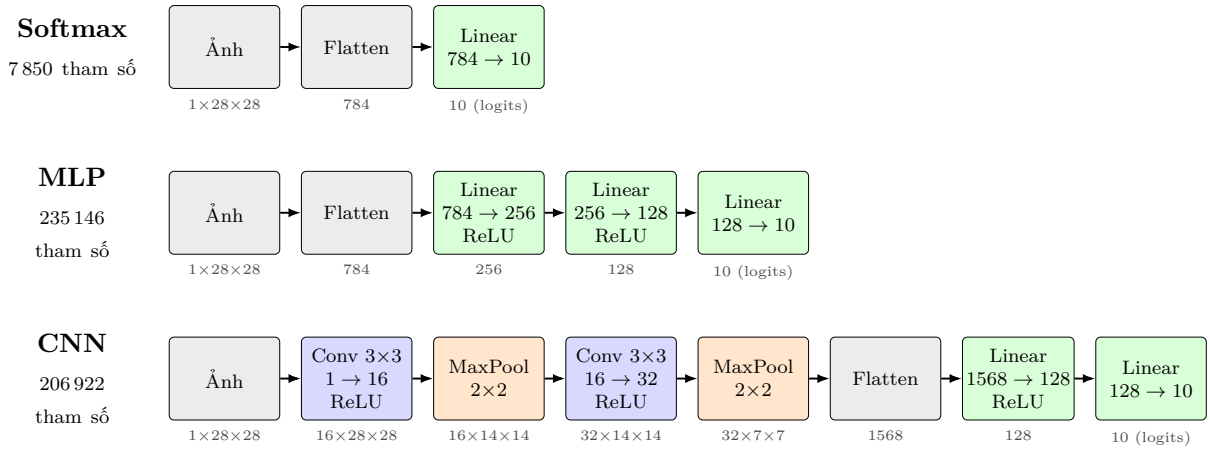
Để đảm bảo khả năng tái lập kết quả, toàn bộ thông số của mỗi thí nghiệm, gồm dữ liệu, kiến trúc mô hình, thuật toán tối ưu hóa và hàm mất mát (loss), được khai báo trong một tệp cấu hình YAML riêng. Vòng lặp huấn luyện do chúng tôi tự viết, gồm lần lượt các bước forward, tính loss, backward và cập nhật tham số, mà không dùng thư viện huấn luyện có sẵn. Mã nguồn, các tệp cấu hình và hướng dẫn chạy lại thí nghiệm được lưu công khai trên GitHub như đã nêu ở Mục 1.

3 E1: Softmax, MLP và CNN

3.1 Mô hình

Phần này so sánh ba kiến trúc có mức ràng buộc về cấu trúc không gian tăng dần. Softmax là bộ phân loại tuyến tính. MLP bổ sung tính phi tuyến nhờ các tầng ẩn, nhưng vẫn coi ảnh là một vector phẳng $x \in \mathbb{R}^{784}$ nên không biết sự liên kết cục bộ của các điểm ảnh. CNN nhận trực tiếp ảnh $1 \times 28 \times 28$ và khai thác tính cục bộ cùng việc chia sẻ trọng số. Mỗi mô hình được huấn luyện ở hai thiết lập là không tăng cường dữ liệu (base) và có tăng cường dữ liệu (aug). Hai thiết lập dùng cùng kiến trúc và cùng số tham số, chỉ khác nhau ở dữ liệu dùng để cập nhật trọng số. Hình 4 minh họa luồng kích thước tensor qua từng mô hình, còn Bảng 3 cho số tham số của từng tầng.

Softmax Mô hình tính logits qua ánh xạ tuyến tính $z = Wx + b$ với $W \in \mathbb{R}^{10\times784}$. Với 7 850 tham số, mô hình học một mẫu tuyến tính cho mỗi lớp.



Hình 4: Sơ đồ kiến trúc ba mô hình của E1. Mỗi khối ghi phép toán, còn kích thước tensor đầu ra nằm ngay dưới khối. Màu xám: đầu vào và flatten; xanh dương: tích chập; cam: pooling; xanh lá: Linear. Đầu ra là logits 10 chiều; hàm softmax được tính bên trong hàm loss.

MLP Mạng sử dụng hai tầng ẩn với cấu trúc $784 \to 256 \to 128 \to 10$ kết hợp hàm kích hoạt ReLU. Nhờ tính phi tuyến, mô hình tạo ra ranh giới quyết định phức tạp hơn, dù vẫn xử lý dữ liệu đầu vào dạng phẳng. Tổng số tham số là 235 146.

CNN Kiến trúc gồm hai khối tích chập 3×3 sử dụng same padding, ReLU và max pooling 2×2, giúp thu nhỏ bản đồ không gian từ 28×28 xuống 7×7 và nâng số kênh lên 32. Sau khi làm phẳng thành vector 1568 chiều, dữ liệu đi qua các tầng Linear $1568 \to 128 \to 10$. Mô hình có tổng số tham số là 206 922. Điểm đáng chú ý là phần lớn trọng số nằm ở các tầng Linear của bộ phân loại, trong khi các tầng tích chập chỉ chiếm khoảng 2,3% tổng số tham số.

3.2 Thiết lập huấn luyện

Quá trình thực nghiệm bao gồm sáu thí nghiệm tương ứng với ba mô hình được huấn luyện trong hai điều kiện có và không có tăng cường dữ liệu. Toàn bộ các thí nghiệm này đều áp dụng chung một thiết lập: bộ tối ưu hóa Adam với tốc độ học 10^{-3}, kích thước batch bằng 64, hàm loss cross-entropy và số epoch tối đa là 1000. Tốc độ học được tự động giảm đi 10 lần khi loss trên tập valid không cải thiện sau 10 epoch, đồng thời huấn luyện sẽ dừng sớm nếu loss trên tập valid chững lại sau 20 epoch. Checkpoint tốt nhất được lựa chọn dựa trên **loss valid nhỏ nhất**.

3.3 Kết quả và phân tích

Accuracy và số tham số Bảng 4 tổng hợp kết quả của sáu thí nghiệm. Với phiên bản base, accuracy test của Softmax, MLP và CNN lần lượt là 92,58%, 97,68% và 98,85%. Tăng cường dữ liệu nâng accuracy của MLP lên 99,07% và của CNN lên 99,50%, nhưng

Bảng 3: Cấu trúc, kích thước đầu ra và số tham số của từng tầng trong các mô hình E1.

Mô hình	Tầng	Kích thước đầu ra	Số tham số
Softmax	Flatten	784	0
	Linear($784 \to 10$)	10	7 850
	Tổng		7 850
MLP	Flatten	784	0
	Linear($784 \to 256$) + ReLU	256	200 960
	Linear($256 \to 128$) + ReLU	128	32 896
	Linear($128 \to 10$)	10	1 290
	Tổng		235 146
CNN	Conv($1 \to 16$, 3×3) + ReLU	$16 \times 28 \times 28$	160
	MaxPool(2)	$16 \times 14 \times 14$	0
	Conv($16 \to 32$, 3×3) + ReLU	$32 \times 14 \times 14$	4 640
	MaxPool(2)	$32 \times 7 \times 7$	0
	Flatten	1568	0
	Linear($1568 \to 128$) + ReLU	128	200 832
	Linear($128 \to 10$)	10	1 290
	Tổng		206 922

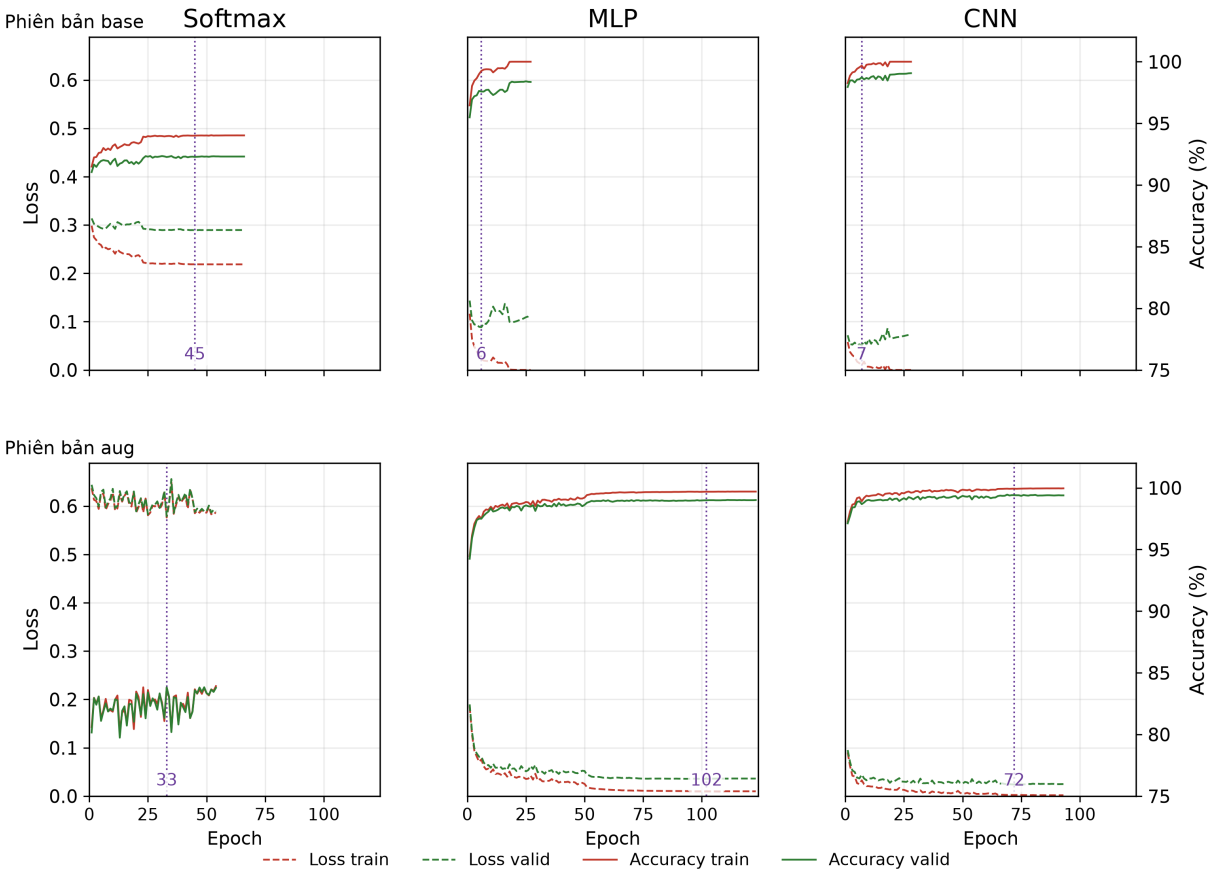
làm accuracy của Softmax giảm xuống 85,12%.

Bảng 4: Kết quả thực nghiệm E1 trên MNIST. Accuracy tính bằng %, đo trên ảnh gốc; Gap là hiệu số giữa accuracy train và valid.

Mô hình	Biến thể	Tham số	Epoch tốt nhất	Train	Valid	Test	Gap
Softmax	base	7 850	45	94,00	92,28	92,58	1,72
Softmax	aug	7 850	33	83,81	83,82	85,12	−0,01
MLP	base	235 146	6	99,26	97,58	97,68	1,68
MLP	aug	235 146	102	99,69	98,99	99,07	0,70
CNN	base	206 922	7	99,68	98,73	98,85	0,95
CNN	aug	206 922	72	99,93	99,41	99,50	0,52

Đường cong huấn luyện Hình 5 cho thấy quá trình thay đổi loss và accuracy của sáu thí nghiệm. Ở phiên bản base, MLP và CNN đạt accuracy cao hơn Softmax và dừng huấn luyện sớm hơn, với checkpoint tốt nhất lần lượt ở epoch 6 và 7. Ở phiên bản aug, quá trình cải thiện của hai mô hình này kéo dài hơn, với checkpoint tốt nhất ở epoch 102 và 72, đồng thời khoảng cách giữa loss và accuracy của tập train so với tập valid thu hẹp lại. Ngược lại, loss của Softmax aug dao động liên tục theo dạng zigzag và quá trình huấn luyện dừng sớm vì mô hình không còn cải thiện được loss valid.

Tổng số lỗi Bảng 5 thống kê số ảnh test bị phân loại sai. Tăng cường dữ liệu giảm số lỗi của MLP từ 232 xuống 93 và của CNN từ 115 xuống 50, nhưng làm số lỗi của Softmax tăng gấp đôi.

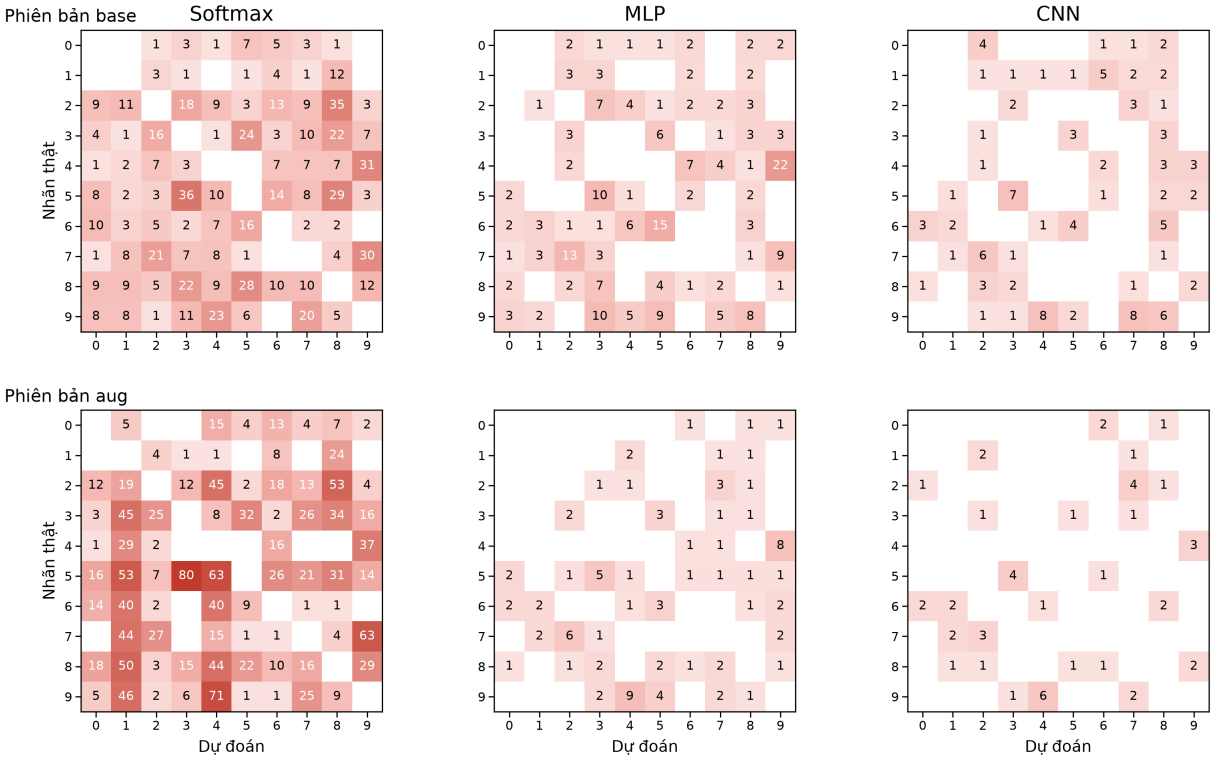


Hình 5: Đường cong loss và accuracy của sáu thí nghiệm trong E1. Trục trái hiển thị loss (nét đứt), trục phải hiển thị accuracy (nét liền); màu đỏ ứng với tập train, màu xanh ứng với valid. Vạch kẻ dọc màu tím đánh dấu epoch đạt hiệu suất tối ưu theo loss valid.

Bảng 5: Số lượng ảnh test bị phân loại sai trên tổng số 10 000 mẫu.

Mô hình	Base	Aug	Thay đổi
Softmax	742	1 488	+100%
MLP	232	93	−60%
CNN	115	50	−57%

Các cặp nhầm lẫn Thang màu ở Hình 6 cho thấy số lỗi giảm dần từ Softmax sang MLP rồi sang CNN. Ở phiên bản base, Softmax nhầm lẫn ở các cặp chữ số có nét giống nhau như 2/8, 3/5, 3/8, 4/9, 5/8 và 7/9. MLP giảm mạnh các lỗi này nhưng vẫn còn nhầm lẫn ở các cặp 4/9 (22 mẫu $4 \to 9$) và 6/5 (15 mẫu $6 \to 5$), còn CNN là mô hình cải thiện rõ rệt nhất. Tăng cường dữ liệu làm giảm nhầm lẫn của MLP và CNN, chẳng hạn $4 \to 9$ ở MLP giảm từ 22 xuống 8 mẫu, nhưng làm Softmax nhầm lẫn nhiều hơn, với các nhầm lẫn lớn nhất là $5 \to 3$ (80 mẫu) và $9 \to 4$ (71 mẫu).

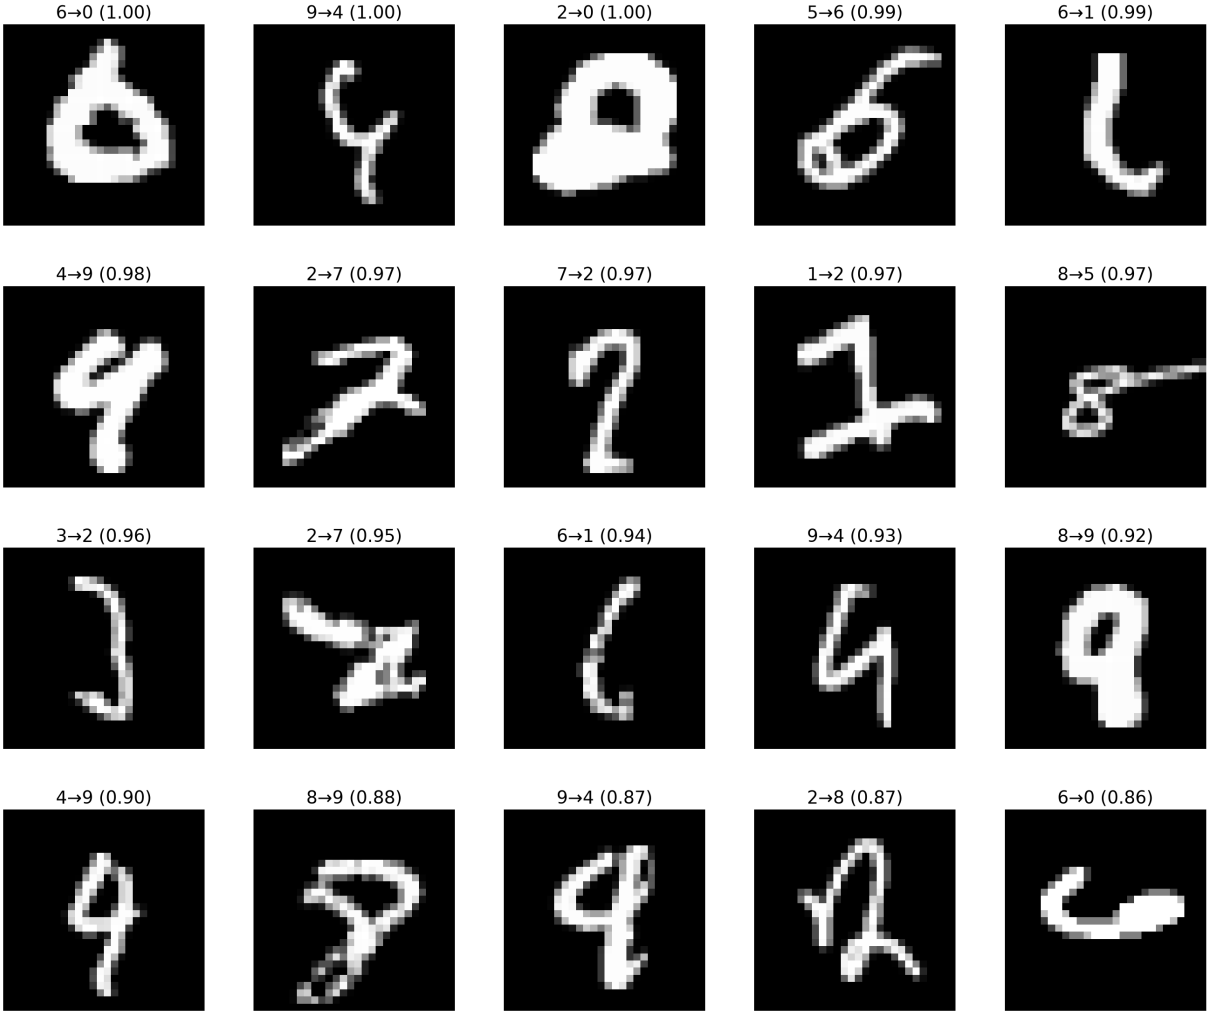


Hình 6: Ma trận nhầm lẫn trên tập test. Ô chéo được để trắng; màu đỏ đậm hơn biểu thị tỉ lệ lỗi cao hơn; số trong mỗi ô là số mẫu bị phân loại sai.

Mẫu bị phân loại sai Hình 7 minh họa các lỗi có độ tự tin cao nhất của CNN aug, là mô hình tốt nhất của bài E1. Một số mẫu khó phân biệt ngay từ hình ảnh: chữ số 6 và chữ số 2 bị nhận nhầm thành 0 vì hình dạng khá giống chữ số 0, còn chữ số 9 viết thiếu nét nên trông giống chữ số 4. Tuy nhiên, cũng có những lỗi cho thấy mô hình chưa tốt, chẳng hạn chữ số 1 bị nhận nhầm thành 2 dù hình dạng khá rõ ràng.

3.4 Thảo luận

Kiến trúc quan trọng hơn số tham số Dù có ít tham số hơn MLP khoảng 12%, CNN chỉ mắc khoảng một nửa số lỗi, cụ thể là 115 so với 232 ở bản base và 50 so với 93 ở bản aug. Tầng Linear đầu tiên của hai mô hình có số tham số gần bằng nhau, lần lượt là 200 832 và 200 960, nên khác biệt chính nằm ở bộ trích xuất đặc trưng. Bộ này chỉ gồm hai tầng tích chập với khoảng 2,3% tổng số tham số của CNN, nhưng khai thác cấu trúc



Hình 7: Một số mẫu test bị phân loại sai có độ tự tin dự đoán cao nhất của CNN tăng cường. Mỗi ảnh ghi nhãn thật → dự đoán và xác suất của lớp dự đoán sai.

cục bộ và chia sẻ trọng số. Do đó, ưu thế của CNN đến từ thiên kiến quy nạp chứ không đến từ số lượng tham số.

Tăng cường dữ liệu nâng cao hiệu quả cho mô hình đủ khả năng biểu diễn Tăng cường dữ liệu giảm số lỗi test của MLP và CNN lần lượt 60% và 57%. Khoảng cách giữa tập train và valid thu hẹp từ 1,68 xuống 0,70 điểm ở MLP và từ 0,95 xuống 0,52 điểm ở CNN, còn epoch tốt nhất dời từ 6 lên 102 ở MLP và từ 7 lên 72 ở CNN. Như vậy tăng cường đóng vai trò điều chuẩn, làm chậm quá khớp và đổi lại thời gian huấn luyện dài hơn.

Hạn chế của mô hình tuyến tính với dữ liệu tăng cường Với Softmax, accuracy test giảm từ 92,58% xuống 85,12% khi có tăng cường dữ liệu. Accuracy train, đo trên ảnh sạch, cũng giảm từ 94,0% xuống 83,8% và gần bằng accuracy valid, nên mô hình đang thiếu khớp chứ không phải quá khớp. Softmax chấm điểm mỗi lớp bằng $w_c^\top x$ với mỗi trọng số gắn với một vị trí điểm ảnh cố định, nên không thể hấp thụ các phép dịch chuyển tới khoảng 2,8 điểm ảnh. Do đó, tăng cường dữ liệu chỉ phát huy hiệu quả khi mô hình đủ khả năng biểu diễn để học được tính bất biến mà nó mang lại.

4 E2: Transformer – MSA và các cách tạo token

4.1 Mô hình

Phần này mô tả bộ phân loại Transformer nông dùng chung cho mọi thí nghiệm E2. Các mô hình chỉ khác nhau ở hai điểm: cách tạo token (hàng, patch 4×4, patch 7×7, patch 8×8 chồng lấn, CNN-stem) và cách cài đặt MSA (tự cài đặt hoặc `nn.MultiheadAttention`). Mỗi cách tạo token đều được huấn luyện với MSA tự cài đặt, và đều có thêm bản PyTorch để đối chiếu.

Multi-Head Self-Attention Cho chuỗi token $X \in \mathbb{R}^{N\times d}$ (N token, chiều $d = d_{\text{model}}$), h đầu và $d_k = d/h$, đầu thứ i tính

$$Q_i = XW_i^Q, \quad K_i = XW_i^K, \quad V_i = XW_i^V, \tag{3}$$

$$\text{head}_i = \text{softmax}\left(\frac{Q_i K_i^\top}{\sqrt{d_k}}\right) V_i, \tag{4}$$

$$\text{MSA}(X) = \text{Concat}(\text{head}_1, \ldots, \text{head}_h)\, W^O, \tag{5}$$

với $W_i^Q, W_i^K, W_i^V \in \mathbb{R}^{d\times d_k}$ và $W^O \in \mathbb{R}^{d\times d}$. Ma trận attention có kích thước $N \times N$ cho mỗi đầu, nên chi phí thời gian tăng theo $O(N^2 d)$ và bộ nhớ theo $O(hN^2)$; điều này quan trọng khi so sánh các cách tạo token.

Bản tự cài đặt Chỉ dùng `Linear`, `einsum` và `softmax`. Một lớp `Linear` duy nhất ($d \to 3d$) tạo cả Q, K, V, với trọng số xếp chồng $[W^Q; W^K; W^V]$ cùng cách xếp với `in_proj_weight` của PyTorch; kết quả được reshape thành $(B, N, 3, h, d_k)$ rồi hoán vị thành $(3, B, h, N, d_k)$. Điểm số $QK^\top/\sqrt{d_k}$ tính bằng `einsum('bhnd,bhmd->bhnm')`, qua softmax theo chiều khóa, rồi dropout trên ma trận attention; đầu ra mỗi đầu là `einsum('bhnm,bhmd->bhnd')` của attention với V. Các đầu được ghép lại thành (B, N, d) và đi qua phép chiếu đầu ra W^O (`Linear` $d \to d$). Bản này không dùng `nn.MultiheadAttention` hay `nn.TransformerEncoder*`.

Bản PyTorch Cùng bộ phân loại nhưng thay MSA bằng `nn.MultiheadAttention` (`batch_first=True`, cùng số đầu và dropout) để đối chiếu. Hai bản dùng chung tokenizer, LayerNorm, FFN, token CLS và đầu phân loại, và với cùng seed thì khởi tạo trọng số giống hệt nhau. Để kiểm tra bản tự cài đặt, chúng tôi sao chép trọng số sang module PyTorch và so sánh đầu ra, attention và gradient trên một số đầu vào ngẫu nhiên (`scripts/e2/check_msa.py`); chênh lệch tối đa khoảng 10^{-7} ở float32 với đầu ra và 2×10^{-5} với gradient.

Kiến trúc bộ phân loại Mỗi cách tạo token đưa ảnh về chuỗi N token và chiếu lên $d_{\text{model}} = 64$. Một token CLS được thêm vào đầu chuỗi, rồi cộng mã hóa vị trí học được kích thước $(N + 1) \times d_{\text{model}}$. Chuỗi đi qua $L = 4$ khối encoder dạng pre-LayerNorm, mỗi khối gồm MSA $h = 4$ đầu ($d_k = 16$) và FFN (`Linear`–GELU–`Linear`, chiều ẩn $d_{ff} = 128 = 2d_{\text{model}}$), mỗi phần có kết nối residual. Dropout $p = 0{,}1$ được đặt trên ma trận attention và trên đầu ra của MSA trước khi cộng residual; ở FFN, dropout nằm giữa GELU và `Linear` thứ hai và không có dropout trên nhánh residual của FFN. Sau một LayerNorm cuối, đầu phân loại (`Linear` $64 \to 10$) áp dụng lên token CLS.

Các cách tạo token Chúng tôi triển khai năm cách tạo token:

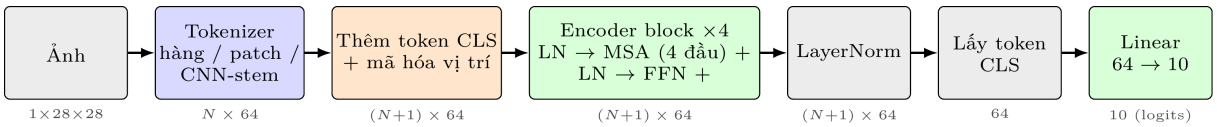
- **Hàng (row)**: mỗi hàng ảnh là một token, $N = 28$ token chiều 28.
- **Patch** 4×4: các ô lưới không chồng lấn, $N = (28/4)^2 = 49$ token chiều 16.
- **Patch** 7×7: $N = (28/7)^2 = 16$ token chiều 49.
- **Patch** 8×8 **chồng lấn**: patch 8×8 với bước (stride) 4, nên hai patch liền kề chồng lên nhau một nửa, cho $N = ((28 - 8)/4 + 1)^2 = 36$ token chiều 64.
- **CNN-stem**: một CNN nhỏ gồm hai khối Conv3×3–BatchNorm–ReLU–MaxPool2×2 (32 rồi 64 kênh) và một Conv1×1 lên 64 kênh, trích bản đồ đặc trưng $C \times H' \times W' = 64 \times 7 \times 7$; mỗi vị trí không gian là một token, $N = H'W' = 49$, chiều $C = 64$.

Cả năm cách đều dùng token CLS và mã hóa vị trí học được; chiều token trong Bảng 6 là số giá trị của mỗi token trước khi được chiếu lên $d_{\text{model}} = 64$; riêng với CNN-stem,

Bảng 6: Số token N và chiều token của từng cách tạo token.

Cách tạo token	N	Chiều token
Hàng	28	28
Patch 4×4	49	16
Patch 7×7	16	49
Patch 8×8 chồng lấn	36	64
CNN-stem	49	64

Conv1 $\times$ 1 nằm trong tokenizer nên token ra khỏi tokenizer đã có 64 chiều. Bảng 6 liệt kê số token.



Hình 8: Sơ đồ bộ phân loại Transformer của E2. Mỗi khối ghi phép toán, còn kích thước tensor đầu ra nằm ngay dưới khối (N là số token, tùy cách tạo token). Màu xám: đầu vào, LayerNorm và lấy token CLS; xanh dương: tokenizer; cam: thêm CLS và mã hóa vị trí; xanh lá: encoder và Linear.

Bảng 7: Số tham số của từng thành phần trong các mô hình E2 ($d_{\text{model}} = 64$). Hai bản MSA có cùng số tham số.

Thành phần	Hàng	Patch 4×4	Patch 7×7	Chồng lấn 8×8	CNN-stem
Tokenizer	1 856	1 088	3 200	4 160	23 168
Token CLS	64	64	64	64	64
Mã hóa vị trí $(N{+}1) \times 64$	1 856	3 200	1 088	2 368	3 200
MSA (4 block)	66 560	66 560	66 560	66 560	66 560
FFN (4 block)	66 304	66 304	66 304	66 304	66 304
LayerNorm (4×2 và cuối)	1 152	1 152	1 152	1 152	1 152
Linear $64 \to 10$	650	650	650	650	650
Tổng	138 442	139 018	139 018	141 258	161 098

4.2 Thiết lập huấn luyện

Quá trình thực nghiệm bao gồm mười thí nghiệm tương ứng với năm cách tạo token, mỗi cách được huấn luyện với MSA tự cài đặt và với MSA của PyTorch. Dữ liệu và cách chia giống E1 (50 000 ảnh train, 10 000 ảnh valid phân tầng với seed 42, 10 000 ảnh test), chỉ chuẩn hóa mean/std và *không* tăng cường dữ liệu. Toàn bộ các thí nghiệm đều áp dụng chung một thiết lập: bộ tối ưu hóa AdamW với tốc độ học 10^{-3} và weight decay 0,05 (chỉ áp lên trọng số của `Linear` và `Conv2d`; bias, tham số chuẩn hóa, token CLS và mã hóa vị trí không bị decay), kích thước batch bằng 128, hàm loss cross-entropy và số epoch tối đa là 200. Tốc độ học được tự động giảm đi 10 lần (`ReduceLROnPlateau`) khi loss trên

tập valid không cải thiện sau 10 epoch, đồng thời huấn luyện sẽ dừng sớm nếu loss trên tập valid chững lại sau 20 epoch. Checkpoint tốt nhất được lựa chọn dựa trên **loss valid nhỏ nhất**, nên accuracy valid và test trong cùng một dòng của bảng thuộc về cùng một mô hình. Mọi thí nghiệm dùng seed 42.

4.3 Kết quả và phân tích

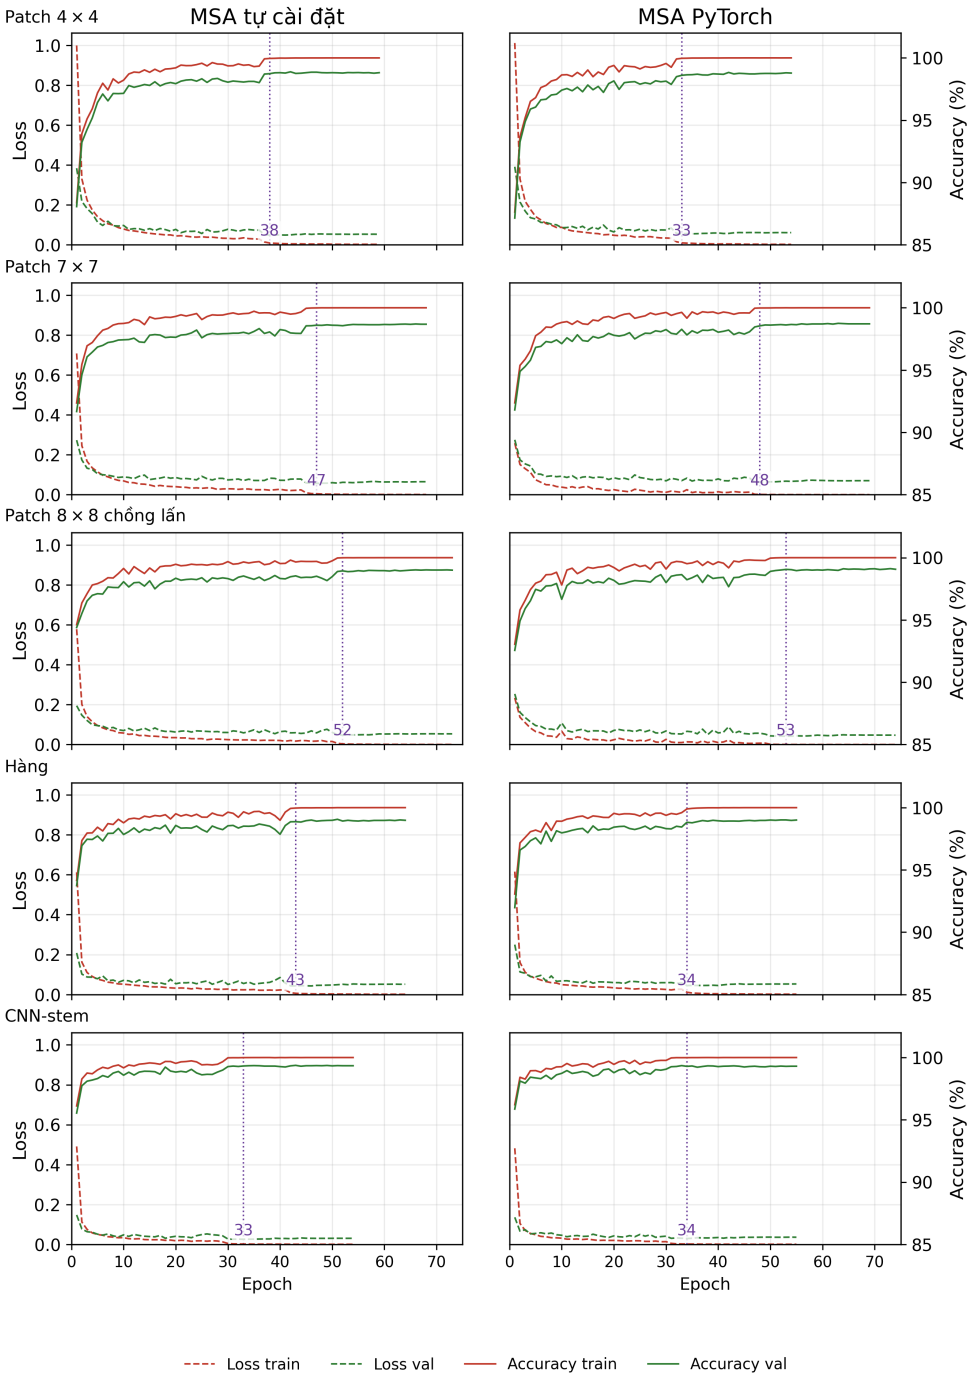
Accuracy và số tham số Bảng 8 tổng hợp kết quả của mười thí nghiệm. Với MSA tự cài đặt, accuracy test xếp từ cao xuống thấp là CNN-stem 99,33%, hàng 99,13%, patch 8×8 chồng lấn 98,98%, patch 4×4 98,85% và patch 7×7 98,70%. Với MSA của PyTorch, accuracy test của năm cách tạo token nằm trong khoảng 98,67% đến 99,49% và CNN-stem cũng dẫn đầu. Ở mọi mô hình, accuracy train gần 100% và Gap giữa train và valid từ 0,67 đến 1,43 điểm, nhỏ nhất ở CNN-stem. Hai bản MSA cho accuracy gần nhau ở cả năm cách tạo token, chênh lệch lớn nhất là 0,19 điểm.

Bảng 8: Kết quả thực nghiệm E2 trên MNIST. Accuracy tính bằng %, đo trên ảnh gốc; Gap là hiệu số giữa accuracy train và val; Epoch là epoch có loss valid nhỏ nhất; Giây/epoch chỉ tính các bước huấn luyện.

Cách tạo token	MSA	Tham số	Epoch	Train	Valid	Test	Gap	Giây/epoch
Patch 4×4	Tự cài đặt	139 018	38	99,95	98,73	98,85	1,22	11,08
	PyTorch	139 018	33	99,96	98,60	98,67	1,36	15,83
Patch 7×7	Tự cài đặt	139 018	47	99,99	98,60	98,70	1,39	11,76
	PyTorch	139 018	48	99,98	98,55	98,80	1,43	15,81
Patch 8×8 chồng lấn	Tự cài đặt	141 258	52	99,99	98,94	98,98	1,05	16,17
	PyTorch	141 258	53	100,00	99,06	99,07	0,94	15,55
Hàng	Tự cài đặt	138 442	43	99,96	98,87	99,13	1,09	16,03
	PyTorch	138 442	34	99,89	98,82	98,94	1,07	10,69
CNN-stem	Tự cài đặt	161 098	33	99,99	99,32	99,33	0,67	16,73
	PyTorch	161 098	34	99,99	99,29	99,49	0,70	15,94

Đường cong huấn luyện Hình 9 cho thấy hai bản MSA có đường cong bám sát nhau ở cả năm cách tạo token. Epoch tốt nhất nằm trong khoảng 33 đến 53; sau epoch đó loss valid gần như phẳng trong khi accuracy train đã gần 100%, và huấn luyện dừng sớm sau 20 epoch không cải thiện.

Tổng số lỗi Bảng 9 thống kê số ảnh test bị phân loại sai. CNN-stem mắc ít lỗi nhất (67 với MSA tự cài đặt và 51 với MSA PyTorch), trong khi patch 4×4 và patch 7×7 mắc từ 115 đến 133 lỗi. Hướng chênh giữa hai bản MSA không nhất quán: bản tự cài đặt mắc ít lỗi hơn ở patch 4×4 và hàng, nhiều lỗi hơn ở ba cách còn lại.

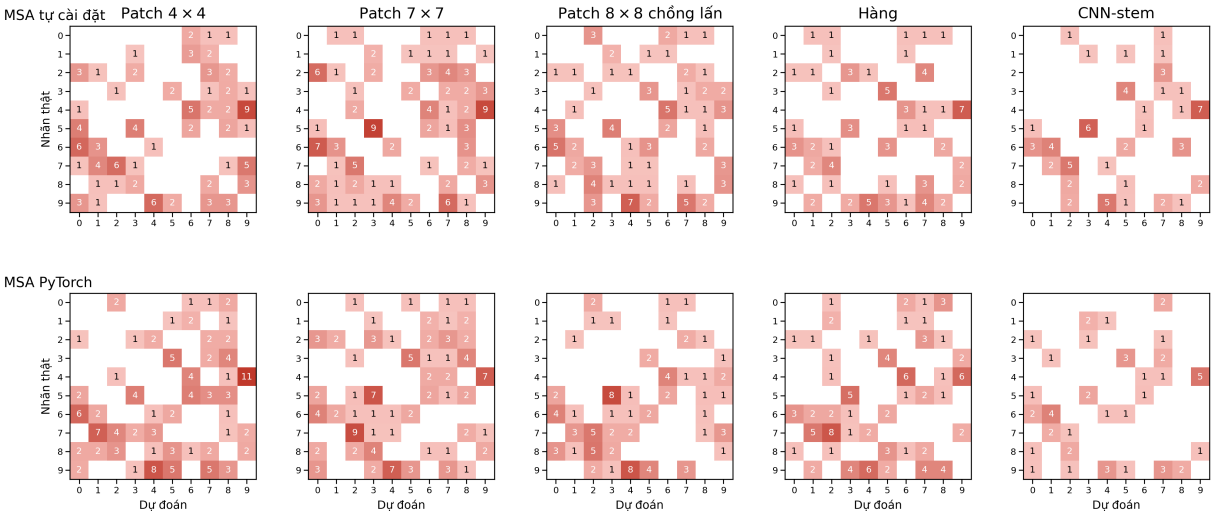


Hình 9: Đường cong học của E2 (nét đứt: loss, trục trái; nét liền: accuracy, trục phải; đỏ: train, xanh lá: val; đường chấm tím: epoch của checkpoint được giữ). Mỗi hàng là một cách tạo token (patch 4×4, patch 7×7, patch 8×8 chồng lấn, hàng, CNN-stem), cột trái là MSA tự cài đặt, cột phải là MSA PyTorch. Hai bản bám sát nhau; loss valid gần như phẳng sau khoảng 40 epoch trong khi accuracy train đã gần 100%.

Bảng 9: Số lượng ảnh test bị phân loại sai trên tổng số 10 000 mẫu.

Cách tạo token	MSA tự cài đặt	MSA PyTorch
Patch 4×4	115	133
Patch 7×7	130	120
Patch 8×8 chồng lấn	102	93
Hàng	87	106
CNN-stem	67	51

Các cặp nhầm lẫn Hình 10 cho thấy ma trận nhầm lẫn của cả mười mô hình. Cặp 4/9 (cả hai chiều) nằm trong ba cặp bị nhầm nhiều nhất ở mọi mô hình, chẳng hạn $4 \to 9$ có 11 mẫu ở patch 4×4 với PyTorch và 9 mẫu ở patch 7×7 với MSA tự cài đặt. Cặp $5 \to 3$ xuất hiện ở mọi mô hình, từ 2 mẫu (CNN-stem, PyTorch) đến 9 mẫu (patch 7×7, tự cài đặt). CNN-stem mắc ít lỗi nhất nên ma trận của nó thưa nhất.

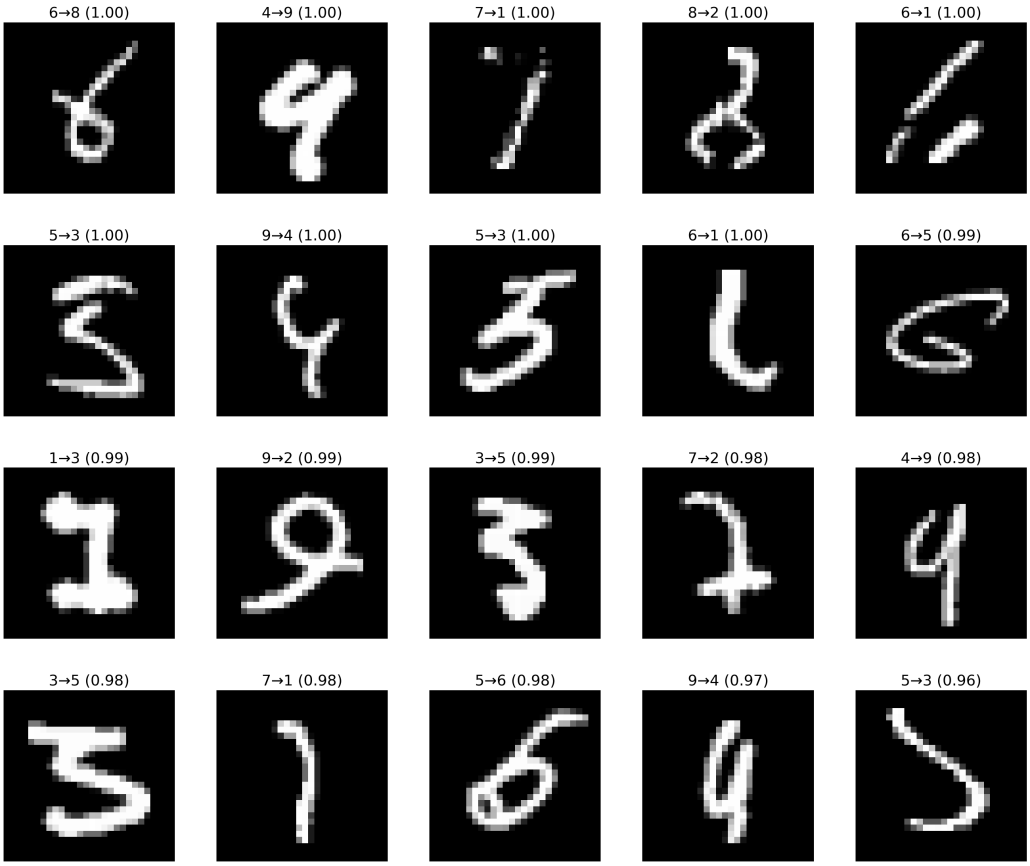


Hình 10: Ma trận nhầm lẫn trên tập test của mười mô hình E2; hàng trên là MSA tự cài đặt, hàng dưới là MSA PyTorch. Ô chéo được để trắng; màu đỏ đậm hơn biểu thị tỉ lệ lỗi cao hơn; số trong mỗi ô là số mẫu bị phân loại sai.

Mẫu bị phân loại sai Hình 11 minh họa các lỗi có độ tự tin cao nhất của CNN-stem với MSA tự cài đặt, là mô hình có accuracy valid cao nhất của bài E2. Hơn một nửa trong số 20 lỗi này thuộc các cặp chữ số vốn dễ nhầm như 4/9, 5/3 và 7/1, trong đó nhiều ảnh viết khác thường, chẳng hạn một nét mảnh bị nhận thành chữ số 1 hoặc chữ số 4 khép kín phần đầu nên giống chữ số 9.

4.4 Thảo luận

Hai bản MSA tương đương Accuracy test của hai bản gần nhau ở cả năm cách tạo token: patch 4×4 98,85% so với 98,67%, patch 7×7 98,70% so với 98,80%, patch chồng lấn 98,98% so với 99,07%, hàng 99,13% so với 98,94%, CNN-stem 99,33% so với 99,49%.



Hình 11: Một số mẫu test bị phân loại sai có độ tự tin dự đoán cao nhất của CNN-stem với MSA tự cài đặt. Mỗi ảnh ghi nhãn thật $\rightarrow$ dự đoán và xác suất của lớp dự đoán sai.

Chênh lệch lớn nhất là 0,19 điểm và hướng chênh không nhất quán (bản tự cài đặt cao hơn ở patch 4×4 và hàng, thấp hơn ở patch 7×7, patch chồng lấn và CNN-stem), nên phù hợp với nhiễu tối ưu hơn là một khác biệt hệ thống. Vì vậy bản MSA tự cài đặt cho kết quả tương đương `nn.MultiheadAttention`. Thời gian mỗi epoch cũng không cho thấy bản nào nhanh hơn: bản tự cài đặt nhanh hơn ở patch 4×4 (11,08 s so với 15,83 s) và patch 7×7 (11,76 s so với 15,81 s) nhưng chậm hơn ở hàng (16,03 s so với 10,69 s) và patch chồng lấn (16,17 s so với 15,56 s). Con số này gồm cả thời gian nạp dữ liệu trên CPU và mỗi lượt chạy diễn ra trên một container riêng, nên nó phản ánh máy chạy nhiều hơn chi phí của mô hình; chúng tôi không dùng nó để so sánh hai cách cài đặt.

Cách tạo token là một dạng thiên kiến quy nạp Với MSA tự cài đặt, accuracy test xếp từ cao xuống thấp là CNN-stem 99,33%, hàng 99,13%, patch 8×8 chồng lấn 98,98%, patch 4×4 98,85% và patch 7×7 98,70%. CNN-stem mang thiên kiến tích chập (tính cục bộ và bất biến tịnh tiến được đưa vào trước khi attention nhìn toàn cục) và dẫn đầu, nhưng cũng có nhiều tham số nhất (161 098, hơn các mô hình còn lại khoảng 16%), nên chưa tách được đóng góp của thiên kiến khỏi đóng góp của dung lượng. Cách tạo token theo hàng giao cho attention tự học quan hệ giữa các hàng. Với MSA tự cài đặt, hàng đạt 99,13% trên test, cao hơn cả ba biến thể patch (98,70% đến 98,98%), dù xếp dưới patch chồng lấn ở accuracy valid (98,87% so với 98,94%). Ngược lại, với MSA PyTorch, patch chồng lấn cao hơn hàng trên test (99,07% so với 98,94%). Chênh lệch của hàng so với patch chồng lấn (0,15 điểm) và patch 4×4 (0,28 điểm) dưới 0,3 điểm; riêng patch 7×7 thấp hơn hàng 0,43 điểm nhưng đây chỉ là kết quả của một seed, và thứ hạng giữa hàng với patch chồng lấn đổi chiều theo cách cài đặt MSA nên chưa ổn định. Giữa các biến thể patch của bản tự cài đặt, chênh lệch tối đa là 0,28 điểm, nhỏ hơn mức dao động mà một seed duy nhất cho phép phân biệt; chúng tôi không rút ra kết luận về kích thước hay độ chồng lấn của patch.

Chi phí theo số token Chi phí của attention tăng theo $O(N^2 d)$ với N từ 16 (patch 7×7) đến 49 (patch 4×4, CNN-stem). Tuy vậy thời gian mỗi epoch không tăng theo N (patch 7×7 11,76 s, hàng 16,03 s, chồng lấn 16,17 s, patch 4×4 11,08 s) vì bị chi phối bởi việc nạp dữ liệu, nên không dùng được để kiểm chứng quan hệ $O(N^2 d)$. Cột ảnh/giây trong `results_e2.csv` đo riêng mô hình: patch 7×7 ($N = 16$) đạt khoảng 8 400–11 000 ảnh/s, patch 4×4 ($N = 49$) khoảng 3 800–4 200 và CNN-stem ($N = 49$) khoảng 2 300–2 600. Patch 7×7 nhanh hơn patch 4×4 khoảng 2,2–2,6 lần, gần với tỉ lệ tuyến tính theo N ($49/16 \approx 3{,}1$) hơn tỉ lệ bậc hai ($(49/16)^2 \approx 9{,}4$). Điều này phù hợp với việc ở $N \leq 49$ và $d = 64$, phần $O(Nd^2)$ của các phép chiếu và FFN lấn át $O(N^2 d)$ của attention. Kết luận này còn hạn chế: ảnh/giây được đo trên CPU của máy phân tích chứ không phải GPU lúc huấn luyện, dao động khoảng 30% giữa các lần đo, và gồm cả chi phí của tokenizer (CNN-stem chậm hơn patch 4×4 dù cùng $N = 49$).

Hạn chế MNIST nhỏ và dễ: cả mười mô hình đều đạt trên 98,6% với chưa tới 162 000 tham số, nên bài toán này khó phân biệt các cách tạo token.

5 E3: LSTM và GRU trên chuỗi ảnh

5.1 Mô hình

Phần này khảo sát khả năng phân loại khi xem ảnh MNIST dưới góc độ dữ liệu chuỗi thay vì không gian 2D hoặc vector phẳng. Chúng tôi triển khai hai kiến trúc hồi quy phổ biến là Long Short-Term Memory (LSTM) [2] và Gated Recurrent Unit (GRU) [1]. Cả hai đều được thiết kế để xử lý các phụ thuộc dài hạn trong chuỗi và giảm thiểu hiện tượng tiêu biến gradient so với RNN truyền thống.

Biểu diễn chuỗi Ảnh đầu vào kích thước 28×28 được xử lý dưới dạng chuỗi theo hàng. Cụ thể, mỗi ảnh được chia thành $T = 28$ bước thời gian, trong đó mỗi bước x_t là một vector hàng có kích thước 28 chiều ($x_t \in \mathbb{R}^{28}$). Cách biểu diễn này bảo toàn thứ tự không gian dọc của ảnh, cho phép mô hình học các mối quan hệ tuần tự từ trên xuống dưới.

Thiết lập kiến trúc Cả hai mô hình đều sử dụng cấu hình 1 lớp.

- **LSTM:** Được cấu hình với kích thước trạng thái ẩn $h_size = 224$. Kết hợp với tầng phân loại Linear ($224 \to 10$), tổng số tham số của mô hình là 229 834.
- **GRU:** Được cấu hình với kích thước trạng thái ẩn $h_size = 256$. Nhờ cơ chế cổng đơn giản hóa, GRU đạt tổng số tham số là 222 218, ít hơn LSTM khoảng 3,3% dù có chiều ẩn lớn hơn.

Trong cả hai trường hợp, vector trạng thái ẩn ở bước thời gian cuối cùng (h_T) được trích xuất và đưa trực tiếp qua một tầng Linear để dự đoán logits của 10 lớp.

5.2 Thiết lập huấn luyện

Hai mô hình LSTM và GRU được huấn luyện trên dữ liệu gốc, tuân thủ quy trình tiền xử lý chuẩn hóa như đã mô tả ở Mục 2.2. Cả hai đều sử dụng chung một thiết lập để đảm bảo so sánh công bằng: bộ tối ưu hóa Adam với tốc độ học 10^{-3}, kích thước batch bằng 64, hàm loss cross-entropy và số epoch tối đa là 1000.

Quá trình huấn luyện được hỗ trợ bởi cơ chế `ReduceLROnPlateau` giảm tốc độ học 10 lần khi loss valid không cải thiện sau 10 epoch và dừng huấn luyện nếu loss valid không cải thiện sau 20 epoch. Checkpoint tốt nhất được lựa chọn dựa trên **loss valid nhỏ nhất**.

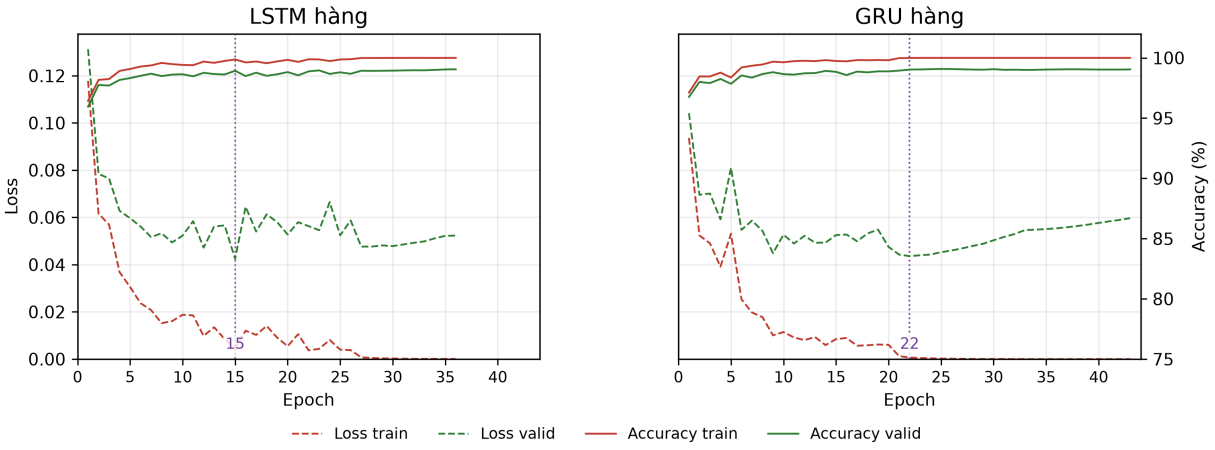
5.3 Kết quả và phân tích

Accuracy và số tham số Bảng 10 tổng hợp kết quả của LSTM và GRU cùng hai mô hình cơ sở không hồi quy là MLP và CNN ở phiên bản base của E1. Test accuracy của LSTM và GRU lần lượt là 98,90% và 98,94%, ngang CNN với 98,85% và cao hơn MLP với 97,68%. Gap của hai mô hình hồi quy là 0,94 và 0,96 điểm, gần với CNN và thấp hơn MLP.

Bảng 10: Kết quả thực nghiệm E3 trên MNIST, kèm MLP và CNN ở phiên bản base của E1. Accuracy tính bằng %, đo trên ảnh gốc; Gap là hiệu số giữa accuracy train và valid.

Mô hình	Tham số	Epoch tốt nhất	Train	Valid	Test	Gap
MLP	235 146	6	99,26	97,58	97,68	1,68
CNN	206 922	7	99,68	98,73	98,85	0,95
LSTM	229 834	15	99,87	98,93	98,90	0,94
GRU	222 218	22	99,99	99,03	98,94	0,96

Đường cong huấn luyện Hình 12 cho thấy quá trình thay đổi loss và accuracy của hai thí nghiệm. Checkpoint tốt nhất của LSTM và GRU lần lượt ở epoch 15 và 22, muộn hơn so với epoch 6 và 7 của MLP và CNN base ở E1.



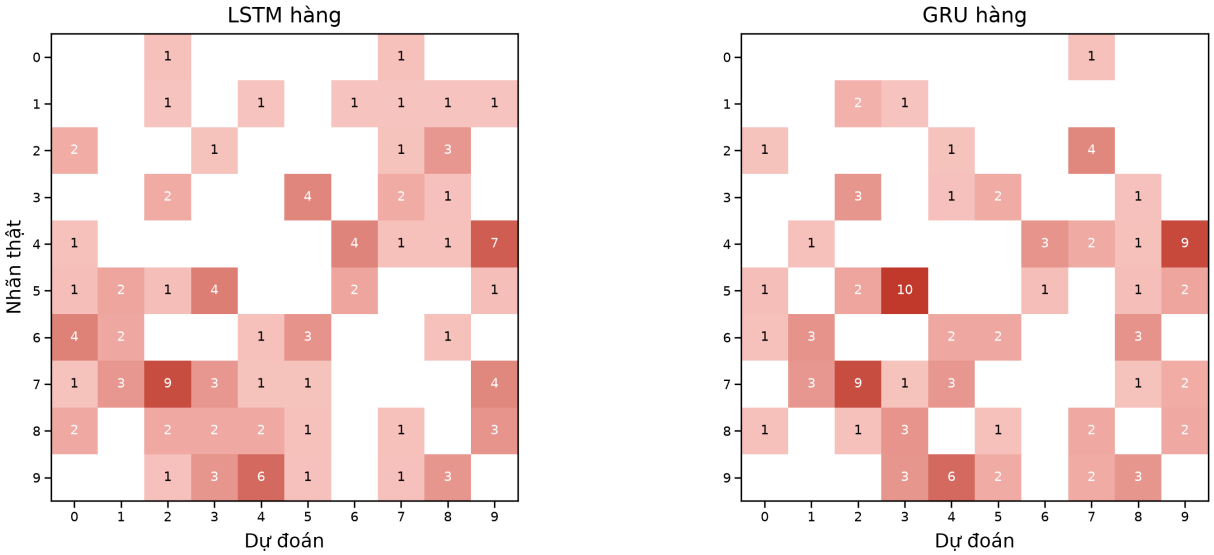
Hình 12: Đường cong loss và accuracy của hai thí nghiệm trong E3. Trục trái hiển thị loss (nét đứt), trục phải hiển thị accuracy (nét liền); màu đỏ ứng với tập train, màu xanh ứng với valid. Vạch kẻ dọc màu tím đánh dấu epoch đạt hiệu suất tối ưu theo loss valid.

Tổng số lỗi Bảng 11 thống kê số ảnh test bị phân loại sai. LSTM mắc 110 lỗi và GRU mắc 106 lỗi, so với 115 lỗi của CNN và 232 lỗi của MLP. Chênh lệch từ 5 đến 9 ảnh giữa hai mô hình hồi quy và CNN cùng cỡ với độ lệch chuẩn khoảng 10 ảnh do tập test có kích thước hữu hạn, và mỗi cấu hình chỉ được huấn luyện một lần. Vì vậy LSTM và GRU được hiểu là ngang CNN chứ không vượt CNN.

Bảng 11: Số lượng ảnh test bị phân loại sai trên tổng số 10 000 mẫu.

Mô hình	MLP	CNN	LSTM	GRU
Số lỗi	232	115	110	106

Các cặp nhầm lẫn Hình 13 cho thấy ma trận nhầm lẫn của LSTM và GRU. Nhầm lẫn lớn nhất của LSTM là $7 \to 2$ với 9 mẫu và $4 \to 9$ với 7 mẫu, còn của GRU là $5 \to 3$ với 10 mẫu, cùng $4 \to 9$ và $7 \to 2$ với 9 mẫu mỗi cặp. So với MLP, cả hai mô hình hồi quy giảm nhầm lẫn $4 \to 9$ từ 22 xuống 7 và 9 mẫu. Cặp $7 \to 2$ vẫn là một trong các nhầm lẫn lớn nhất ở cả bốn mô hình, với 13, 6, 9 và 9 mẫu lần lượt ở MLP, CNN, LSTM và GRU.



Hình 13: Ma trận nhầm lẫn trên tập test. Ô chéo được để trắng; màu đỏ đậm hơn biểu thị tỉ lệ lỗi cao hơn; số trong mỗi ô là số mẫu bị phân loại sai.

Phụ thuộc vào các hàng của ảnh Checkpoint tốt nhất của cả bốn mô hình, gồm MLP và CNN của E1, được đánh giá lại trên tập test chỉ còn 14 hàng đầu hoặc 14 hàng cuối và không huấn luyện lại. Các hàng không giữ được thay bằng giá trị nền $-0{,}1308/0{,}3082 \approx -0{,}424$ trong không gian đã chuẩn hóa, nên mọi mô hình vẫn nhận đầu vào 28×28. Bảng 12 cho thấy cả bốn mô hình giảm mạnh, nhưng LSTM và GRU giảm nhiều hơn MLP và CNN ở cả hai nửa. Với 14 hàng đầu, LSTM và GRU đạt 30,16% và 30,20%, so với 47,99% và 54,03% của MLP và CNN. Với 14 hàng cuối, LSTM và GRU đạt 41,88% và 40,69%, so với 51,88% và 59,94%. Các chênh lệch từ 10 đến 24 điểm này lớn hơn nhiều so với sai số lấy mẫu của tập test. Phần thông tin thiếu được thay bằng một đoạn hàng nền liên tiếp dài hơn nhiều so với vài hàng nền ở mép ảnh gốc, nên kết quả đo mức nhạy của từng mô hình với phép thay thế này chứ không đo khả năng xử lý thông tin thiếu nói chung.

Bảng 12: Test accuracy (%) khi chỉ giữ một phần các hàng của ảnh. Các hàng không giữ được thay bằng giá trị nền.

Mô hình	Đầy đủ	14 hàng đầu	14 hàng cuối
MLP	97,68	47,99	51,88
CNN	98,85	54,03	59,94
LSTM	98,90	30,16	41,88
GRU	98,94	30,20	40,69

5.4 Thảo luận

Mô hình hồi quy ngang CNN với số tham số tương đương Ma trận chuyển trạng thái chiếm 196 608 trên 222 218 tham số của GRU và 200 704 trên 229 834 tham số của LSTM, tức khoảng 88% và 87%. Ma trận này có cùng cỡ với tầng Linear đầu tiên của MLP và CNN, khoảng 2×10^5 tham số, nhưng được áp dụng lặp lại ở cả 28 bước thay vì một lần. Ma trận trọng số đầu vào cũng được dùng chung cho mọi hàng, tương tự cách CNN dùng chung bộ lọc cho mọi vị trí, trong khi tầng đầu tiên của MLP có một trọng số riêng cho từng điểm ảnh. Việc chia sẻ trọng số theo chiều dọc của ảnh có thể giải thích vì sao LSTM và GRU ngang CNN và vượt MLP với cùng ngân sách tham số.

Mô hình hồi quy nhạy hơn với việc thay các hàng bằng giá trị nền Tầng đầu tiên của MLP cộng đóng góp của từng điểm ảnh, nên thay một số hàng bằng giá trị nền chỉ cộng thêm một thay đổi vào đầu vào của mỗi nơ-ron và không ảnh hưởng đến phần còn lại của ảnh. CNN chỉ trích xuất đặc trưng cục bộ, nên các hàng bị thay chỉ ảnh hưởng đến đặc trưng quanh vùng đó. Ở LSTM và GRU, thay đổi tại bước t làm thay đổi mọi trạng thái $h_{t'}$ với $t' \geq t$ và do đó làm thay đổi cả h_T dùng để phân loại, nên sai lệch lan qua các chuyển trạng thái phi tuyến. Một đoạn dài hàng nền liên tiếp cũng có thể đưa trạng thái ẩn đến vùng mà khi huấn luyện mô hình chỉ gặp vài hàng nền ở đầu và cuối chuỗi. Điều này phù hợp với việc LSTM và GRU mất nhiều accuracy hơn MLP và CNN trong Bảng 12.

LSTM và GRU không có khác biệt rõ rệt Ở cùng kích thước ẩn, GRU có ít hơn LSTM một phần tư số tham số vì chỉ có ba khối cổng thay vì bốn. Với số tham số tương đương, GRU dùng kích thước ẩn 256 so với 224 của LSTM, và số ảnh test bị nhầm của hai mô hình chỉ khác nhau 4 ảnh. Chuỗi chỉ dài 28 bước, nên thiết kế của LSTM chưa cho thấy lợi thế đo được trên bài toán này.

6 Kết luận

- Kiến trúc quan trọng hơn số tham số: CNN vượt MLP dù ít tham số hơn.

- Tăng cường dữ liệu tương tác với dung lượng mô hình: giảm khoảng 60% số lỗi của MLP và CNN nhưng làm giảm hiệu quả của softmax vì mô hình này thiếu khớp.
- Với cùng cách cài đặt MSA, CNN-stem cho accuracy test cao nhất trong năm cách tạo token (99,33% với MSA tự cài đặt và 99,49% với MSA PyTorch). MSA tự cài đặt gần `nn.MultiheadAttention`: chênh tối đa 0,19 điểm và đổi chiều giữa các cách tạo token.
- Khi đọc ảnh theo từng hàng, LSTM và GRU đạt accuracy test 98,90% và 98,94% với khoảng 2×10^5 tham số, ngang CNN với 98,85% và vượt MLP với 97,68%. Hai mô hình hồi quy không khác biệt rõ rệt.
- Khi chỉ giữ 14 hàng của ảnh, LSTM và GRU mất nhiều accuracy hơn MLP và CNN, cho thấy các mô hình hồi quy phụ thuộc nhiều hơn vào việc có đủ các hàng của chuỗi.

Tài liệu

[1] Kyunghyun Cho, Bart van Merriënboer, Caglar Gulcehre, Dzmitry Bahdanau, Fethi Bougares, Holger Schwenk, and Yoshua Bengio. Learning phrase representations using RNN encoder–decoder for statistical machine translation. In Alessandro Moschitti, Bo Pang, and Walter Daelemans, editors, *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1724–1734, Doha, Qatar, October 2014. Association for Computational Linguistics.

[2] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Comput.*, 9(8):1735–1780, November 1997.

[3] Y. Lecun, L. Bottou, Y. Bengio, and P. Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.